Universidad Autónoma del Estado de Hidalgo

Instituto de Ciencias Básicas e Ingeniería

Licenciatura en Ciencias Computacionales

Sistema Autónomo para la Optimización y Control de Inventarios con Modelos Predictivos

---

Proyecto Computacional

Presenta:

Roberto Omar Cruz Roldán

Directora:

Mtra. Ma. Judith Franco Torres

Pachuca de Soto, Hgo., México., Noviembre 2025

A mis padres y hermanas,

por su apoyo incondicional.

A los que no saben cuándo parar,

ni quieren aprenderlo.

Resumen

Palabras clave: Gestión de inventarios, analítica predictiva, automatización, PyMEs, Prophet, microservicios.

La gestión de inventarios en las Pequeñas y Medianas Empresas (PyMEs) enfrenta un desafío crítico: la alta dependencia de procesos manuales, reactivos y propensos al error humano, lo que genera costosos desequilibrios entre el desabastecimiento y el exceso de stock. Las soluciones tecnológicas avanzadas, como los sistemas ERP, suelen ser inaccesibles debido a su alto costo y complejidad, perpetuando una brecha digital que limita la competitividad.

Este documento presenta el diseño, desarrollo e implementación de un prototipo funcional de Sistema Autónomo de Gestión de Inventarios (SAGI), orientado a ser una solución eficiente y de bajo costo accesible para las PyMEs. El sistema se basa en una arquitectura modular de microservicios que integra un módulo predictivo para el pronóstico de la demanda, utilizando el modelo Prophet de Meta, seleccionado por su robustez en contextos con datos limitados y un motor de orquestación que dota al sistema de autonomía para la toma de decisiones.

El SAGI ejecuta flujos de trabajo automatizados para gestionar proactivamente el inventario, incluyendo la generación de órdenes de compra ante niveles críticos y la aplicación de estrategias de descuento ante excesos de stock. La validación del prototipo demostró la viabilidad de la arquitectura propuesta, cumpliendo con los requisitos funcionales y estableciendo un modelo de "Autonomía Supervisada" que optimiza la operación logística. Se concluye que es factible implementar sistemas autónomos y predictivos en entornos de PyMEs utilizando tecnologías accesibles, ofreciendo una herramienta clave para mejorar su eficiencia operativa y cerrar la brecha tecnológica.

Abstract

Keywords: Inventory management, predictive analytics, automation, SMEs, Prophet, microservices.

Inventory management in Small and Medium-sized Enterprises (SMEs) faces a critical challenge: a high dependency on manual, reactive, and human error-prone processes, which leads to costly imbalances between stock-outs and overstocking. Advanced technological solutions, such as ERP systems, are often inaccessible due to their high cost and complexity, perpetuating a digital divide that limits competitiveness.

This document presents the design, development, and implementation of a functional prototype of an Autonomous Inventory Management System (SAGI), oriented as an efficient, low-cost solution accessible to SMEs. The system is based on a modular microservices architecture that integrates a predictive module for demand forecasting, using Metas's Prophet model, selected for its robustness in limited data contexts and an orchestration engine (n8n) that provides the system with decision-making autonomy.

The SAGI executes automated workflows to proactively manage inventory, including generating purchase orders at critical levels and applying discount strategies for excess stock. The prototype's validation demonstrated the viability of the proposed architecture, meeting functional requirements and establishing a "Supervised Autonomy" model that optimizes logistics operations. It is concluded that implementing autonomous and predictive systems in SME environments using accessible technologies is feasible, offering a key tool to improve their operational efficiency and close the technological gap.

Índice

Resumen **2**

Abstract **3**

1. Introducción **10**

1.1. Planteamiento del Problema 10

1.2. Justificación 12

1.3. Objetivos 13

1.3.1. Objetivo General 13

1.3.2. Objetivos Específicos 13

1.4. Alcances y Limitaciones 14

1.5. Metodología 16

2. Marco Teórico **18**

2.1. Conceptos Fundamentales 18

2.1.1. Definición y Objetivos de la Gestión de Inventarios 18

2.1.2. Tipos de Inventario y su Función en la Cadena de Suministro . . 19

2.1.2.1. Clasificación Según el Estado Físico 19

2.1.2.2. Tipos de Inventario Estratégico 20

2.1.3. Costos e Indicadores Clave de Control de Inventarios 21

2.1.3.1. Estructura de Costos de Inventario 21

2.1.3.2. Indicadores Clave de Desempeño (KPIs) 21

2.1.4. Problemáticas Comunes en PyMEs 22

2.1.4.1. El Riesgo Dual: Desabastecimiento y Sobrestock 23

2.1.4.2. Errores Humanos y Falta de Información Oportuna . . . 23

2.2. Transformación Digital en las PyMEs 24

2.2.1. Contexto Económico y Vulnerabilidad de las PyMEs 24

2.2.2. Digitalización, Automatización y Transformación Digital 25

2.2.2.1. Digitalización 25
2.2.2.2. Automatización de Procesos 25
2.2.2.3. La Transformación Digital (TD) 26
2.2.3. Beneficios Operacionales 26
2.2.3.1. Mejora de la Eficiencia Operativa y Reducción de Errores 27
2.2.3.2. Beneficios Financieros y Estratégicos 27
2.2.4. Cuantificación de la Brecha Digital en las PyMEs Mexicanas . . . 28
2.2.4.1. Estratificación de la Adopción por Tamaño 28
2.2.5. Barreras Clave para la Adopción Tecnológica en el Entorno Mexicano 30
2.2.5.1. Obstáculos Financieros y de Infraestructura 30
2.2.5.2. Obstáculos Gerenciales y Culturales 30
2.2.5.3. Obstáculos de Conocimiento y Estrategia 31
2.3. Analítica Predictiva y Modelos de Predicción de Demanda 32
2.3.1. Concepto y Fundamentos de la Analítica Predictiva 32
2.3.2. Modelos de Series Temporales: ARIMA, SARIMA, Prophet 33
2.3.2.1. Modelo ARIMA 33
2.3.2.2. Modelo SARIMA 35
2.3.2.3. Modelo Prophet 36
2.3.3. Modelos de Machine Learning (ML) para Analítica Predictiva . . 37
2.3.3.1. Fundamentos y Enfoque 37
2.3.3.2. Modelos de ML No Profundo (Shallow Learning) 37
2.3.4. Ventajas del Modelo Prophet en Entornos con Pocos Datos 38
2.3.5. Limitaciones del Uso de Deep Learning en PyMEs 39
2.3.5.1. Restricciones por Volumen y Calidad de Datos 39
2.3.5.2. Carga Computacional y Barreras Económicas 40
2.3.6. Evaluación del Rendimiento Predictivo (Métricas de Error) 40
2.3.6.1. Error Absoluto Medio (MAE) 40
2.3.6.2. Raíz del Error Cuadrático Medio (RMSE) 41
2.3.6.3. Error Porcentual Absoluto Medio (MAPE) 41

2.4. Automatización y Autonomía en los Sistemas de Negocio 42
2.4.1. Concepto General de Automatización y Autonomía 42
2.4.1.1. Diferencia Entre Automatizar y Dotar de Autonomía . . 42
2.4.1.2. De la Automatización a la Autonomía 43
2.4.1.3. Contexto Actual en Entornos Empresariales y Logísticos 43
2.4.2. Tecnologías y Herramientas de Automatización 43
2.4.2.1. Robotic Process Automation (RPA) 44
2.4.2.2. Integración de Sistemas Mediante APIs y Orquestadores 44
2.4.3. Sistemas Autónomos y Toma de Decisiones Automatizada 44
2.4.3.1. Concepto de Autonomía Computacional 45
2.4.3.2. Percepción, Decisión y Acción 45
2.4.3.3. Niveles de Autonomía (Asistida, Supervisada y Completa) 45
2.4.4. Beneficios, Riesgos y Consideraciones en PyMEs 46
2.4.4.1. Impacto en Eficiencia, Costos y Escalabilidad 46
2.4.4.2. Riesgos Asociados (Dependencia, Sesgo y Falta de Transparencia) 47

3. Diseño y Desarrollo del Sistema Autónomo de Gestión de Inventarios (SAGI) 48
3.1. Requisitos del Sistema 48
3.1.1. Requisitos Funcionales 48
3.1.2. Requisitos No Funcionales 49
3.2. Arquitectura General del Sistema 50
3.2.1. Diseño Lógico 50
3.2.2. Arquitectura de Despliegue 52
3.2.3. Tecnologías y Dependencias 52
3.2.3.1. Dependencias del SAGI Core (Sistema Principal) 52
3.2.3.2. Dependecias del Servicio de Generación de PDF 54
3.2.3.3. Dependencias del Servicio de Predicción 54
3.3. Módulo Core de Inventario 54

3.3.1. Funcionalidad y Responsabilidades 55
3.3.2. Modelo de Datos 56
3.3.3. API y Endpoints 57
3.3.4. Flujos Internos 57
3.4. Módulo Predictivo 58
3.4.1. Objetivo y Flujo General 59
3.5. Módulo de Generación de PDFs 59
3.5.1. Descripción General 60
3.5.2. Proceso de Renderizado y Salida 61
3.6. Motor Prescriptivo y Orquestación (n8n) 61
3.6.1. Rol y Funcionamiento General 61
3.6.2. Flujo de Reabastecimiento 63
3.6.3. Flujo de Descuentos 64
3.7. Conclusiones del Capítulo 66

4. Evaluación y Validación del Prototipo 67
4.1. Ambiente y Escenario de Pruebas 67
4.2. Validación de Requisitos Funcionales (RF) 67
4.3. Evaluación del Módulo Predictivo (MAP) 69
4.3.1. Evaluación de la Precisión del Modelo 69
4.3.2. Validación de la Tolerancia a Fallos (RNF-06) 69
4.4. Evaluación de Requisitos No Funcionales (RNF) 70
4.4.1. Rendimiento y Latencia (RNF-01) 70
4.4.2. Usabilidad y Trazabilidad Documental 71

5. Conclusiones y Trabajo Futuro 72
5.1. Conclusiones 72
5.2. Limitaciones del Prototipo 73
5.3. Trabajo Futuro 74

Índice de cuadros

1. Clasificación de Costos de Inventario 22
2. Delimitación Conceptual: Digitalización, Automatización y Transformación Digital 26
3. Indicadores Clave de Adopción Tecnológica en Unidades Económicas Mexicanas 29
4. Tabla de Requisitos del SAGI 49
5. Tabla de Requisitos No Funcionales del SAGI 50
6. Tabla de Arquitectura de Componentes del SAGI 53
7. Tabla de Dependencias del SAGI Core 53
8. Tabla de Dependencias del PDF Service 54
9. Tabla de Dependencias del Prediction Service 55
10. Tabla de Endpoints de la API del SAGI Core 58
11. Tabla de Resultados de Pruebas Funcionales 68
12. Tabla de Validación de Tolerancia a Fallos (RNF-06) 69
13. Tabla de Resultados de Pruebas de Latencia (RNF-01) 70

Índice de figuras

1. Uso de equipo de cómputo e internet en las unidades económicas 29
2. Edad del personal ocupado en las unidades económicas 31
3. Nivel de estudios del personal ocupado en las unidades económicas 31
4. Diagrama lógico de la arquitectura del SAGI 52
5. Diagrama erd del SAGI Core 57
6. Ejemplo de ejecución del Módulo Predictivo 60
7. Ejemplo de PDF generado para una Orden de Compra 62
8. Diagrama inicial del flujo de orquestación en n8n 63
9. Diagrama del flujo de reabastecimiento en n8n 64
10. Diagrama del flujo de descuentos en n8n 66

1. Introducción

En la era de la transformación digital, la capacidad de una empresa para competir se mide por su agilidad para convertir datos en decisiones estratégicas. Mientras las grandes corporaciones invierten masivamente en inteligencia artificial y analítica avanzada para optimizar sus operaciones, una brecha tecnológica crítica se marca en el sector de las Pequeñas y Medianas Empresas (PyMEs).

Ningún área es más sensible a esta brecha que la gestión de la cadena de suministro. El control de inventarios, en particular, ha evolucionado de ser un simple registro contable a convertirse en el eje principal de la eficiencia operativa y la satisfacción del cliente.

Tradicionalmente, la gestión de inventarios ha operado bajo un paradigma reactivo. Sin embargo, los avances en el análisis predictivo y la automatización de procesos abren la puerta a un nuevo enfoque: sistemas que no solo registran, sino que anticipan, deciden y actúan de forma autónoma.

Este documento explora el diseño y la viabilidad de un sistema de esta naturaleza. Se propone un prototipo funcional que integra modelos predictivos y orquestación autónoma, diseñado específicamente para ser accesible y funcional en el contexto de las PyMEs, buscando ofrecer una solución tangible a los desafíos operativos que enfrentan.

1.1. Planteamiento del Problema

En el entorno empresarial moderno, caracterizado por su alta competitividad, la gestión de inventarios se considera un componente esencial en la cadena de suministro de cualquier empresa, desempeñando un papel crucial en la eficiencia operativa y la rentabilidad [34]. Los errores logísticos tienen consecuencias financieras significativas, amplificadas por la necesidad de satisfacer la demanda de manera inmediata y mantener costos bajos [34].

En primer lugar, el Riesgo de Desabastecimiento (Stock-Out). La incapacidad para cumplir rápidamente con los pedidos conduce a la insatisfacción del cliente y, en el largo plazo, a la pérdida de ventas y un impacto negativo en la reputación corporativa

[10]. Prevenir el desabastecimiento es vital para la fluidez de las operaciones y para salvaguardar la rentabilidad de la empresa. En segundo lugar, el Riesgo de Exceso de Stock, que refiere a la acumulación excesiva, inmoviliza capital de trabajo, incrementa los costos de almacenamiento y aumenta la vulnerabilidad a pérdidas por deterioro u obsolescencia, lo que reduce los beneficios y limita el crecimiento [10].

Una limitación central es la dependencia de administradores para la toma de decisiones críticas, lo que introduce la posibilidad de errores humanos por omisión o retraso y decisiones basadas en la intuición en lugar de en datos objetivos. Además, la mayoría de estos procesos son reactivos, es decir, responden únicamente cuando el problema ya es evidente, en lugar de anticiparse a la variación futura de la demanda [46].

El desafío logístico se agudiza en el segmento de las pequeñas y medianas empresas (PyMEs), las cuales representan la mayoría de las empresas existentes en países como México [17]. A pesar de su importancia económica, la incorporación de tecnologías digitales en este segmento es significativamente menor en comparación con las grandes corporaciones.

Las soluciones avanzadas de planificación de recursos empresariales (ERP) y las plataformas de análisis predictivo suelen estar dirigidas a grandes corporaciones, presentando costos elevados y requerimientos técnicos complejos para PyMEs [29]. Esta brecha tecnológica genera una desigualdad competitiva que limita la capacidad de las empresas pequeñas para optimizar sus recursos y reaccionar de manera eficiente ante los cambios en la demanda [21].

El problema central identificado es la necesidad de un tránsito tecnológico de los sistemas de inventario meramente informativos a soluciones verdaderamente autónomas y accesibles para PyMEs [34]. Se requiere el desarrollo de un sistema capaz de tomar decisiones estratégicas, como la predicción de demanda y la generación de órdenes de compra, basándose en datos y operando con mínima intervención humana.

1.2. Justificación

La implementación de un Sistema Autónomo de Gestión de Inventarios (SAGI) se justifica por la necesidad de que las PyMEs optimicen sus operaciones mediante soluciones tecnológicas accesibles y adaptables. En muchos entornos empresariales, la gestión de inventarios sigue siendo un proceso manual, reactivo y propenso a errores, lo que ocasiona pérdidas por sobreabastecimiento, desabasto o una mala asignación de recursos. De hecho, se estima que el 46 % de las PyMEs aún utiliza un sistema manual para el seguimiento de su inventario, lo que inevitablemente genera errores y contratiempos costosos [2]. Un sistema autónomo permite detectar, decidir y actuar de manera proactiva, mejorando la eficiencia operativa y reduciendo la dependencia de la supervisión humana constante [65]. La mala administración del inventario en PyMEs puede repercutir en clientes descontentos y problemas financieros que pueden llevar a puntos críticos [21].

Desde una perspectiva operativa y tecnológica, el proyecto propone la integración de herramientas de automatización, análisis de datos y comunicación digital que trabajen de forma coordinada para optimizar el flujo de inventario. Mediante procesos automatizados, el sistema puede identificar bajos niveles de stock y generar órdenes de compra de forma automática o con validación humana, además de reconocer excesos de inventario y sugerir acciones correctivas como descuentos o promociones [37]. La automatización del proceso de órdenes de compra, por ejemplo, es un beneficio estratégico que agiliza el procesamiento, evita pagos en exceso o duplicados y soporta un mayor volumen de transacciones sin requerir más personal administrativo [37]. Estas capacidades buscan mejorar la continuidad operativa, minimizar pérdidas y aumentar la agilidad en la toma de decisiones. Estudios de caso demuestran que la automatización de inventarios ha logrado reducir en un 25 % el exceso de productos y disminuir los tiempos de reabastecimiento en empresas del sector [43].

La propuesta técnica se fundamenta en el uso de arquitecturas modulares y tecnologías actuales de automatización de procesos, analítica predictiva e integración de servicios, las cuales pueden implementarse con recursos limitados. La analítica predicti-

va, definida como el empleo de datos, algoritmos estadísticos e inteligencia artificial para identificar probabilidades de escenarios futuros, se aplica para mejorar la gestión de inventarios y optimizar la asignación de recursos [20]. Esto permite a las PyMEs acceder a herramientas inteligentes sin requerir grandes inversiones en infraestructura ni personal especializado. Así, el SAGI no solo facilita la modernización de la gestión de inventarios, sino que también democratiza el acceso a la transformación digital [28].

Finalmente, el proyecto contribuye a cerrar la brecha tecnológica entre grandes corporaciones y pequeñas empresas. Aunque las PyMEs representan el 99.8 % de los negocios en México y generan más del 70 % del empleo, menos del 30 % ha adoptado herramientas digitales [17]. Al demostrar que es posible construir un sistema autónomo, eficiente y de bajo costo con tecnologías abiertas y escalables, se valida un modelo replicable que puede adaptarse a distintos sectores y niveles de madurez tecnológica. En conjunto, el SAGI representa una propuesta viable para impulsar la eficiencia y competitividad de las PyMEs mediante la automatización inteligente de sus procesos de inventario.

1.3. Objetivos

1.3.1. Objetivo General

Diseñar e implementar un prototipo funcional de Sistema Autónomo de Gestión de Inventarios (SAGI) que integre analítica predictiva y automatización de procesos para anticipar la demanda, ejecutar flujos automáticos de reabastecimiento y aplicar estrategias dinámicas ante exceso de inventario, con el fin de evaluar su eficacia en la mejora de la eficiencia operativa

1.3.2. Objetivos Específicos

1. Analizar la viabilidad de aplicar modelos de predicción de demanda en contextos con datos limitados, identificando el enfoque que ofrezca la mejor relación entre simplicidad técnica y precisión.

2. Diseñar la arquitectura modular del SAGI, definiendo la interacción entre los mó-

dulos de gestión de inventario, analítica predictiva y automatización, priorizando la escalabilidad, la integración mediante estándares y la facilidad de implementación.

3. Implementar el módulo de analítica predictiva seleccionado, entrenándolo con datos históricos de inventario para generar pronósticos de demanda y evaluar su rendimiento mediante métricas de error.

4. Desarrollar los flujos automatizados que ejecuten acciones concretas, como la generación de órdenes de compra automáticas y la aplicación de estrategias de descuento ante exceso de stock.

5. Validar empíricamente el desempeño del prototipo comparando métricas clave frente a un proceso manual base, con el propósito de determinar la mejora en eficiencia operativa y precisión de pronóstico.

1.4. Alcances y Limitaciones

El proyecto se concibe como un prototipo funcional de un Sistema Autónomo de Gestión de Inventarios, orientado a validar la viabilidad de la autonomía en la gestión de inventarios dentro de un marco accesible para PyMEs. Su alcance funcional se centra en la gestión básica de productos y la logística predictiva, incluyendo:

- Predicción de demanda futura mediante modelos de analítica predictiva de baja complejidad, adaptados a los datos disponibles.

- Generación automática o semiautomática de órdenes de compra cuando se detectan niveles de inventario críticos.

- Aplicación de reglas de descuento o promoción ante exceso de inventario, como estrategia para optimizar flujo de productos.

Se excluyen deliberadamente módulos externos a la gestión de inventario, como contabilidad, recursos humanos o facturación, enfocando los recursos del prototipo únicamente en la funcionalidad clave. La autonomía del sistema se complementa con la gestión

de excepciones por parte del personal, garantizando control humano sobre acciones críticas y minimizando riesgos operativos, práctica estándar en sistemas automatizados [48].

Desde el punto de vista tecnológico, se prioriza simplicidad, eficiencia y accesibilidad:

- Se implementarán modelos de analítica predictiva de baja complejidad, como Prophet o modelos de series temporales simples, adecuados para PyMEs con datos limitados y problemas acotados [25]. Prophet, en particular, ha demostrado ser una herramienta robusta y adaptable para pronósticos de negocio con datos limitados y puede generar predicciones razonablemente precisas incluso con datos dispersos [58].

- Se evitará el uso de algoritmos de alta complejidad, como Deep Learning o redes neuronales, que requieren grandes volúmenes de datos y recursos computacionales [33].

- La integración con proveedores se realizará mediante canales comunes de bajo costo, sin recurrir a conectores comerciales complejos, manteniendo la viabilidad económica y técnica del prototipo. La integración de interfaces de programación de aplicaciones (APIs) es un componente esencial en la automatización de procesos de negocio, permitiendo el intercambio de datos sin intervención humana y minimizando imprecisiones [34].

Entre las principales limitaciones, se identifican:

- Dependencia de los datos históricos de ventas, cuya calidad y consistencia impactan directamente en la precisión de los pronósticos [19]. Esta dependencia es un limitante fundamental, ya que una predicción inexacta obliga a modificar el modelo.

- Exclusión de variables externas complejas, como indicadores macroeconómicos o análisis de sentimiento, que podrían mejorar la predicción, pero son difíciles de obtener para PyMEs [40]. Esta exclusión puede limitar la capacidad del modelo para adaptarse a cambios inesperados en el entorno de mercado.

- Seguridad y auditoría limitada, ya que el prototipo se enfoca en validar la funcionalidad predictiva y prescriptiva, sin implementar cifrado extremo a extremo ni controles avanzados de acceso.

La validación empírica del prototipo se realizará mediante comparación con la gestión manual o semi-automatizada, utilizando métricas clave, asegurando un marco cuantitativo que respalde la eficacia del SAGI.

1.5. Metodología

El proyecto se desarrollará siguiendo una metodología ágil basada en Scrum, adecuada para la creación de un prototipo funcional de Sistema Autónomo de Gestión de Inventarios (SAGI) que integra analítica predictiva y automatización de procesos. Este enfoque permite organizar el desarrollo en ciclos iterativos, con entregables parciales y retroalimentación continua, facilitando la validación empírica y la mejora progresiva del prototipo, lo cual es esencial en el entorno de recursos limitados y requerimientos cambiantes de las PyMEs.

De acuerdo con lo especificado en la Guía de Scrum [63], toda la metodología descrita a continuación se basa en los principios y prácticas recomendadas por este marco ágil.

Planificación del Proyecto

En esta fase se definen los objetivos del primer sprint, se identifican los requerimientos funcionales mínimos (gestión de inventario, predicción de demanda, generación de órdenes automáticas y aplicación de reglas de descuento) y se establecen las métricas de éxito que permitirán evaluar el desempeño del prototipo. Se determina además la secuencia de sprints, los recursos disponibles y los criterios de aceptación de cada módulo del sistema.

Desarrollo Iterativo

El desarrollo se organiza en sprints cortos, cada uno orientado a un conjunto específico de funcionalidades:

- Preparación de datos y módulo predictivo: Revisión, limpieza y tratamiento de los

datos históricos de ventas, selección de atributos relevantes y entrenamiento del modelo de predicción.

- Diseño de la arquitectura modular: Definición de la interacción entre la base de datos de inventario, el módulo predictivo y el motor de automatización, priorizando escalabilidad, modularidad y facilidad de integración.

- Implementación del flujo prescriptivo: Configuración de reglas para generar órdenes de compra automáticas o semiautomáticas y aplicar descuentos ante exceso de inventario, garantizando la continuidad operativa y la reducción de tareas repetitivas.

- Integración y pruebas del prototipo: Consolidación de los módulos desarrollados, ejecución de escenarios de prueba y ajuste de parámetros según métricas de desempeño previamente definidas.

Evaluación y Validación

Al final de cada sprint, se evalúan los resultados obtenidos frente a los objetivos establecidos. La validación se realiza mediante la comparación de las métricas del prototipo con la línea base manual o semi-automatizada, asegurando que la eficiencia operativa y la precisión del pronóstico cumplan los criterios definidos.

Documentación y Despliegue del Prototipo

Una vez completados los sprints, se documenta el proceso de desarrollo, los resultados obtenidos y las lecciones aprendidas. El prototipo se despliega en un entorno controlado, compatible con la infraestructura típica de PyMEs, garantizando que la solución sea replicable y escalable para futuras implementaciones.

2. Marco Teórico

2.1. Conceptos Fundamentales

El siguiente apartado establece la base que sustenta la necesidad y el diseño del Sistema Autónomo de Gestión de Inventarios (SAGI), unido a la problemática de las Pequeñas y Medianas Empresas (PyMEs) dentro del contexto de la logística moderna. La gestión de inventarios se entiende como un desafío de optimización crítica cuya deficiencia se traduce en riesgos operativos y financieros, sobre todo en entornos con recursos y capacidades tecnológicas limitadas.

2.1.1. Definición y Objetivos de la Gestión de Inventarios

La gestión de inventarios va más allá de contar productos, sino que es un conjunto de prácticas y decisiones orientadas a mantener el flujo de mercancías desde el proveedor hasta el cliente, asegurando disponibilidad, reduciendo costos y evitando pérdidas por obsolescencia [34]. En la literatura logística se la describe como un proceso integral que incluye el rastreo, el control y la planificación de las existencias, y que resulta clave para la eficiencia de la cadena de suministro [34].

Desde una perspectiva académica, la gestión de inventarios es una herramienta que ayuda a las empresas en la correcta administración y control de sus productos mediante la definición clara de políticas, métodos y procedimientos. Andrade y Guerrero subrayan la importancia de esta actividad al afirmar que una gestión bien estructurada permite reducir costos y mejorar el flujo de operaciones. En un entorno empresarial moderno, la gestión de inventario es vista como un desafío que abarca la administración efectiva de recursos, la reducción de gastos operacionales y el cumplimiento eficiente de las demandas variadas de los clientes [3].

El objetivo principal de la gestión de inventarios es alcanzar un equilibrio entre el nivel de servicio y la optimización de los costos operativos [26]. Este objetivo se desglosa en metas estratégicas y operacionales concretas:

- **Garantizar el nivel de servicio:** Tener el producto correcto disponible en el lugar y momento adecuados para evitar pedidos incumplidos y pérdida de clientes.
- **Reducir costos:** Mantener inventarios que minimicen el capital inmovilizado y los gastos de almacenamiento sin sacrificar disponibilidad.
- **Mejorar la planificación:** Optimizar previsiones y procesos para coordinar compras, producción y reposición de forma más eficiente.

Estas metas buscan equilibrar servicio y coste en la operación cotidiana [47].

La gestión de inventarios representa un problema de optimización con diferentes objetivos, donde los fines de minimizar los costos, evitando el exceso de stock, y maximizar la disponibilidad, evitando el desabasto, son opuestos [47]. La resolución efectiva de este dilema depende de la capacidad del sistema para gestionar la incertidumbre generada por la variabilidad de la demanda y los tiempos de suministro [47]. Cuando las empresas, especialmente las PyMEs, dependen de sistemas manuales o reactivos, no logran cuantificar esta incertidumbre de forma objetiva. Esto obliga a los administradores a basar las decisiones críticas en la intuición o a reaccionar solo cuando el problema es evidente, causando una oscilación ineficiente entre los dos riesgos principales [50].

2.1.2. Tipos de Inventario y su Función en la Cadena de Suministro

El inventario es una clasificación estructurada de activos que desempeñan funciones específicas a lo largo del ciclo productivo y logístico. Chase, Jacobs y Aquilano definen el inventario como las existencias de artículos de cualquier tipo o recurso usados en una organización, clasificándolo en función de su estado físico y, estratégicamente, en función de su rol operacional en la cadena de suministro [12].

2.1.2.1 Clasificación Según el Estado Físico

Según Chopra y Meindl, la clasificación más común, aplicable tanto a fabricantes como a distribuidores, se basa en la etapa del proceso en la que se encuentran los bienes [13]:

- **Materias Primas y Componentes:** Son los insumos básicos o partes compradas por la empresa y almacenados hasta que el proceso de producción o ensamblaje los requiere. Su función principal es desacoplar el proceso de adquisición del proceso de producción, permitiendo que las operaciones de fabricación continúen incluso si hay interrupciones o retrasos en el suministro.

- **Productos en Curso:** Representan los materiales que han comenzado su transformación, pero aún no se han completado. Este inventario sirve para mantener el flujo operativo entre diferentes etapas de fabricación, actuando como un amortiguador contra las variaciones o los tiempos de espera inherentes a las fases intermedias.

- **Productos Terminados:** Inventario que ha completado su proceso de producción y está listo para ser vendido al cliente final. Su función estratégica es garantizar la disponibilidad inmediata para cumplir con la demanda anticipada, asegurando el nivel de servicio y la capacidad de respuesta.

2.1.2.2 Tipos de Inventario Estratégico

Además de la clasificación física, existen categorías basadas en la utilidad del stock para la continuidad del negocio:

- **Mantenimiento, Reparación y Operaciones (MRO):** Este inventario incluye suministros no destinados a la venta directa, pero que son esenciales para el soporte y la continuidad de los procesos de producción, como piezas de repuesto o lubricantes. Su función es mitigar el riesgo de paradas operativas no planificadas y asegurar la disponibilidad de los equipos clave [9].

- **Inventario Gestionado por el Proveedor (VMI):** VMI es un método de gestión colaborativa de la cadena de suministro en el que el proveedor rastrea y gestiona los movimientos de stock del cliente, generalmente materias primas o subconjuntos [9].

La función estratégica general del inventario es actuar como un amortiguador contra la incertidumbre en la demanda, los tiempos de entrega y las fallas en el suministro

[31]. Es importante notar que mantener sólidas relaciones con los proveedores y garantizar la coherencia en las entregas es fundamental para mitigar los riesgos asociados a la incoherencia en la calidad y los retrasos, tanto para las materias primas como para los suministros MRO.

2.1.3. Costos e Indicadores Clave de Control de Inventarios

La rentabilidad de la gestión de inventarios se mide mediante el análisis de su estructura de costos y el seguimiento de Indicadores Clave de Desempeño (KPIs). Financieramente, las existencias se rigen por principios contables, como la Norma Internacional de Contabilidad 2 (NIC 2), la cual establece el tratamiento contable de los inventarios, incluyendo qué costos deben ser reconocidos como un activo diferido [11].

2.1.3.1 Estructura de Costos de Inventario

La gestión financiera del inventario se rige por la comprensión de que los costos se dividen en tres grandes categorías, un marco conceptual ampliamente aceptado en la literatura de logística y gestión de operaciones, como lo describen autores como Chase, Jacobs y Aquilano [12]:

2.1.3.2 Indicadores Clave de Desempeño (KPIs)

Los indicadores permiten medir la eficiencia y confiabilidad de los procesos logísticos, siendo esenciales para la toma de decisiones. La medición de estos KPIs es fundamental para lograr el equilibrio entre costos y servicio [9]:

- **Exactitud en Inventario (Inventory Accuracy):** Este indicador mide la confiabilidad de la información de stock lógico en comparación con el stock físico. La falta de precisión es un problema recurrente en la literatura de gestión de almacenes y se considera un KPI crítico de control interno [68].
- **Rotación de Inventario (Inventory Turnover Ratio):** Mide la velocidad con la que el inventario se vende y se reemplaza en un periodo, identificando la eficiencia en

Tipo de Costo	Descripción Detallada	Impacto Estratégico
Costos de Almacenamiento	Erogaciones por mantener el inventario en existencia. Incluyen: costo del capital inmovilizado, espacio físico, manejo, seguros, impuestos y pérdidas por deterioro u obsolescencia.	Inmovilizan el capital de trabajo, incrementan el riesgo de pérdidas por deterioro y reducen la rentabilidad directa de la empresa.
Costos de Pedido	Gastos administrativos y logísticos incurridos al colocar órdenes de compra. Incluyen: selección y gestión de proveedores, trámites, transporte, inspección y recepción.	Determinan la frecuencia óptima de reabastecimiento. La reducción de estos costos es un objetivo clave del Modelo de Cantidad Económica de Pedido (EOQ).
Costos de Ruptura de Stock	Pérdidas asociadas a la incapacidad de satisfacer la demanda inmediatamente. Incluyen: pérdida de venta, penalizaciones contractuales, retrasos en producción y daño a la reputación corporativa.	Impactan directamente el Nivel de Servicio y la lealtad del cliente. Su minimización es el objetivo principal del stock de seguridad.

Cuadro 1: *Clasificación de Costos de Inventario. Fuente: Elaboración propia basada en Chase, Jacobs y Aquilano [12].*

la gestión de existencias. Un índice bajo puede indicar sobrestock u obsolescencia. El indicador es central para evaluar la eficiencia con la que se utiliza el capital inmovilizado y se calcula como la relación entre el costo de las mercancías vendidas y el valor del inventario promedio [68].

- **Nivel de Servicio (Fill Rate):** Porcentaje de pedidos o líneas de pedido que se cumplen inmediatamente desde el inventario disponible. Mide el éxito en la prevención del desabastecimiento y es la métrica principal utilizada para balancear la inversión en inventario con las expectativas del cliente [68].

2.1.4. Problemáticas Comunes en PyMEs

Las PyMEs enfrentan desafíos logísticos potenciados por una marcada brecha tecnológica que las expone a riesgos duales, ambos con consecuencias financieras y operativas significativas. La mala gestión de inventario es señalada consistentemente como uno de los errores más comunes que cometen estas empresas.

2.1.4.1 El Riesgo Dual: Desabastecimiento y Sobrestock

La gestión ineficiente del inventario en PyMEs se caracteriza por la oscilación entre dos extremos logísticos:

- **Desabastecimiento:** Este fenómeno se define como la incapacidad de cumplir rápidamente con los pedidos del cliente. Tiene un alto costo asociado a la insatisfacción, la pérdida inmediata de ventas y el deterioro de la reputación corporativa [5]. El desabastecimiento es a menudo el resultado de una mala previsión de la demanda o de plazos de entrega inconsistentes por parte de los proveedores. En las PyMEs, la falta de existencias se confirma como un factor que influye negativamente en la rentabilidad de la empresa [5].

- **Exceso de Inventario:** La acumulación excesiva de inventario inmoviliza capital de trabajo e incrementa los costos de almacenamiento y los riesgos de obsolescencia [9]. Operativamente, el sobrestock genera una pérdida de espacio físico y puede llevar a una falta de organización de la mercancía y a una congestión en el almacén [44]. Esta ineficiencia en el almacenamiento complica la localización y el picking, afectando la eficiencia interna y, en última instancia, la experiencia del cliente [44]. La acumulación de sobrestock es un problema que se observa con frecuencia en las PyMEs que no logran reducir el inventario al nivel mínimo [9].

2.1.4.2 Errores Humanos y Falta de Información Oportuna

Los desafíos del stock-out y el sobrestock en PyMEs se ven fuertemente influenciados por factores internos vinculados a la carencia de procesos y tecnología formalizados:

- **Inventario Desactualizado y Errores Operativos:** La diferencia entre el stock lógico y el físico es un problema constante en almacenes debido a fallas en la manipulación de la mercancía, errores en el picking y una gestión manual o deficiente del stock [9]. Estos errores operativos son más prevalentes en empresas con falta de sistematización y personal no capacitado en técnicas modernas de gestión de inventarios [5].

- **Falta de Información Oportuna:** Un problema central en las PyMEs es la falta de información oportuna generada por sus sistemas contables. Las gerencias se ven obligadas a tomar decisiones críticas basándose en la intuición o información desactualizada, en lugar de datos confiables, lo que incrementa la incertidumbre y alimenta la oscilación ineficiente entre desabastecimiento y sobrestock [52].

2.2. Transformación Digital en las PyMEs

La gestión empresarial actual exige la integración de estrategias tecnológicas para garantizar la supervivencia y el crecimiento en mercados globalizados y altamente dinámicos. En este contexto, la Transformación Digital (TD) emerge no como una opción de mejora operativa, sino como un necesario estratégico fundamental para mantener la competitividad, especialmente en el segmento de las PyMEs. Diversos autores señalan que la TD es un factor de supervivencia que redefine los modelos de negocio y la propuesta de valor en el contexto de la Industria 4.0, siendo inevitable para la sostenibilidad a largo plazo [54]. Esta sección se dedica a definir conceptualmente la TD, cuantificar el rezago tecnológico en México, y analizar los beneficios y barreras que enfrentan las PyMEs nacionales al intentar modernizar sus procesos.

2.2.1. Contexto Económico y Vulnerabilidad de las PyMEs

Esta brecha tecnológica se manifiesta en procesos de gestión reactivos, manuales y propensos a errores, particularmente en áreas logísticas críticas como la gestión de inventarios. La dependencia de administradores para la toma de decisiones críticas introduce la posibilidad de errores humanos y juicios basados en la intuición en lugar de en datos objetivos, lo que afecta la eficiencia y la planificación [59]. Esta ineficiencia se traduce en riesgos financieros amplificados, como el Riesgo de Desabastecimiento, que conduce a la pérdida de ventas y daño reputacional, y el Riesgo de Exceso de Stock, que inmoviliza capital e incrementa los costos por almacenamiento y potencial obsolescencia [27].

El problema subyacente radica en que las soluciones avanzadas de planificación de recursos empresariales (ERP) y las plataformas de análisis predictivo, aunque necesarias,

están tradicionalmente dirigidas a grandes corporaciones, presentando altos costos de licenciamiento, implementación y requerimientos de hardware, lo que las hace financiera y técnicamente inaccesibles o desproporcionadas para la mayoría de las PyMEs mexicanas [59].

2.2.2. Digitalización, Automatización y Transformación Digital

Es fundamental diferenciar la Transformación Digital de los conceptos instrumentales de Digitalización y Automatización. Si bien estos últimos son componentes necesarios, la TD representa un cambio estratégico que va más allá de la mera implementación de software.

2.2.2.1 Digitalización

La digitalización se refiere primariamente al proceso de convertir información que existe en formato analógico a un formato digital accesible. En un sentido más amplio, implica la adopción de tecnologías para generar cambios en las formas de trabajo, los roles y la oferta de negocio, al aprovechar los datos ya digitalizados [75]. Para las PyMEs con una baja madurez digital, la digitalización suele significar la implementación de herramientas básicas como el correo electrónico, bases de datos o sistemas de seguimiento de inventario basados en hojas de cálculo, lo que mejora la organización y la accesibilidad de la información [75]. Sin embargo, la digitalización por sí misma no modifica la estrategia fundamental de negocio.

2.2.2.2 Automatización de Procesos

La Automatización implica el uso de tecnología específica para ejecutar tareas repetitivas y operativas de forma autónoma, con el objetivo directo de reducir o eliminar la intervención humana [62]. La automatización busca maximizar la eficiencia operativa y minimizar los errores humanos, permitiendo a las empresas manejar un mayor volumen de transacciones sin requerir personal administrativo adicional [62]. En el contexto de la gestión de inventarios, la automatización se manifiesta en la configuración de flujos

que ejecutan acciones concretas, como la generación automática de órdenes de compra o la aplicación de reglas de descuento al detectar excesos de stock. La automatización, por lo tanto, es una herramienta táctica poderosa para mejorar la eficiencia logística y la productividad [7].

2.2.2.3 La Transformación Digital (TD)

La Transformación Digital es la etapa más profunda y estratégica. Se define como la integración radical de nuevas Tecnologías Digitales en diversas áreas del negocio, lo que resulta en un cambio significativo en la cultura organizacional, la forma de trabajar y, crucialmente, la creación de nuevos Modelos de Negocio que generan ingresos más rentables y mayor ventaja competitiva [75].

La relación jerárquica entre estos conceptos se resume en la siguiente tabla:

Concepto	Propósito Central	Alcance Principal	Impacto Estratégico
Digitalización	Convertir la información analógica en formato digital.	Procesos documentales y de comunicación.	Mejora la organización y accesibilidad de la información.
Automatización	Uso de tecnología para ejecutar tareas repetitivas de forma autónoma.	Flujos operativos específicos.	Aumenta la eficiencia, reduce errores humanos y minimiza costos.
Transformación Digital	Integración radical de TD para crear nuevos modelos de negocio y culturas organizacionales.	Estrategia holística que afecta la cadena de valor, la cultura y la oferta de servicios.	Genera ventaja competitiva, resiliencia y nuevas fuentes de ingresos.

Cuadro 2: *Delimitación Conceptual: Digitalización, Automatización y Transformación Digital. Fuente: Elaboración propia basada en Unosquare [75]*

.

2.2.3. Beneficios Operacionales

La Transformación Digital, impulsada por tecnologías avanzadas como la Inteligencia Artificial y la analítica predictiva, ofrece beneficios cuantitativos y cualitativos cruciales para las PyMEs que buscan mitigar riesgos y acelerar su crecimiento [54].

2.2.3.1 Mejora de la Eficiencia Operativa y Reducción de Errores

Uno de los principales motores para la adopción tecnológica es la promesa de optimización operativa. La digitalización de procesos internos reduce los gastos operativos directos y minimiza los posibles errores humanos, lo cual impacta positivamente en el flujo de caja de las pequeñas empresas. De hecho, estudios de percepción empresarial indican que el aumento de la eficiencia es el beneficio más valorado por las organizaciones al implementar soluciones basadas en IA, por encima de la reducción de costos o el impulso a la innovaci [41].

La gestión de inventarios es un caso aislado de mejora de la eficiencia. Diversos estudios señalan que casi el 46 % de las pequeñas y medianas empresas no realizan un seguimiento de inventario o aún confían en métodos manuales u hojas de cálculo para el seguimiento de stock, lo que genera contratiempos y pérdidas costosas [60]. En contraste, la evidencia de estudios de caso demuestra que la automatización de inventarios optimiza los niveles de existencias, reduce los costosos errores humanos y minimiza el stock muerto o excedente, además de mejorar la agilidad en el el tiempo de cumplimiento de pedidos [54].

2.2.3.2 Beneficios Financieros y Estratégicos

Desde la perspectiva financiera, la TD y la automatización son aliados estratégicos para reducir costos y mejorar la asignación de recursos. La implementación de la analítica predictiva, permite a las PyMEs prever la demanda y optimizar los niveles de inventario, reduciendo el exceso de stock y mejorando la rotación de productos [22]. Esto se alinea con la percepción empresarial de que la mejora en la toma de decisiones es un beneficio significativo, ya que permite a los líderes empresariales anticiparse a las variaciones del mercado en lugar de limitarse a reaccionar cuando el problema ya es evidente [54].

Además, la adopción de soluciones modernas, especialmente aquellas basadas en la computación en la nube, facilita el crecimiento operacional o la escalabilidad rentable [72]. Estas soluciones ofrecen la capacidad de expansión sin requerir grandes inversiones iniciales en infraestructura física, permitiendo a las PyMEs competir eficazmente con

corporaciones más grandes al optimizar los recursos de TI [72].

La justificación financiera para el desarrollo de un sistema predictivo accesible se centra en el Retorno de Inversión (ROI). La automatización, al eliminar la administración manual, la opacidad y los errores en los procesos, permite a las compañías lograr un ROI anual positivo, duplicando incluso los ahorros en algunos casos de estudio [56]. Dado que la ineficiencia logística ataca el flujo de caja mediante el riesgo de desabastecimiento y el exceso de stock, la inversión en automatización de inventarios no debe interpretarse como un lujo, sino como una necesidad crítica para la estabilidad financiera, enfocándose en la mitigación de las mayores fuentes de pérdida económica en el segmento PyME.

2.2.4. Cuantificación de la Brecha Digital en las PyMEs Mexicanas

A pesar de la importancia estratégica y los beneficios operacionales demostrados, el nivel de madurez digital de las PyMEs mexicanas es calificado de "incipiente" [54]. Es crucial señalar que en 2025, las Micro, Pequeñas y Medianas Empresas (MIPYMES) constituyen el 99.9 % de las unidades económicas del país, siendo las microempresas las predominantes, con el 95.5 % del total, las pequeñas el 3.7 % y las medianas el 0.7 % [17]. Los datos oficiales del Instituto Nacional de Estadística y Geografía (INEGI) cuantifican esta brecha de manera alarmante, evidenciando una profunda desigualdad en la adopción tecnológica en función del tamaño de la empresa [17].

A nivel nacional, la brecha tecnológica es evidente: como se muestra en Figura 1, en 2023 solo el 25.3 % de las unidades económicas utilizó equipo de cómputo, y apenas el 26.2 % empleó internet para llevar a cabo sus actividades [17]. Estudios recientes revelan que menos del 30 % de las micro, pequeñas y medianas empresas en México han integrado herramientas digitales en sus operaciones, una estadística que subraya la amplitud del rezago tecnológico [54].

2.2.4.1 Estratificación de la Adopción por Tamaño

El análisis de los Censos Económicos del INEGI muestra una correlación directa entre el tamaño de la unidad económica y su nivel de adopción tecnológica, lo cual

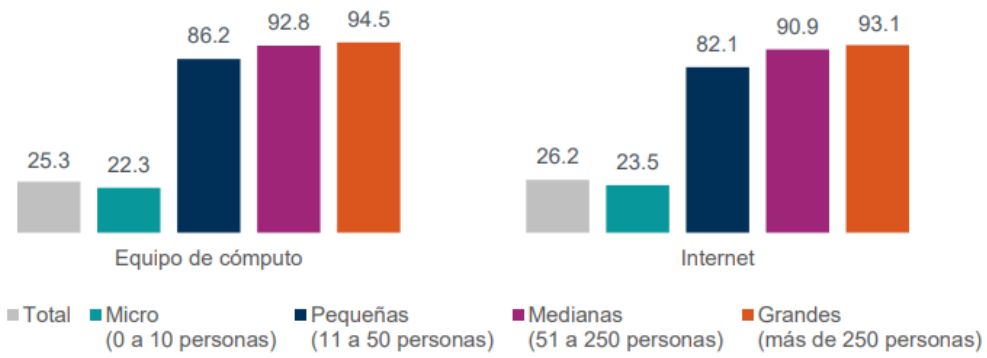

Figura 1: *Uso de equipo de cómputo e internet en las unidades económicas. Fuente: INEGI. Censos Económicos (CE), Resultados oportunos, 2024.*

agudiza la brecha de competitividad [17]. Esta estratificación es visible en la adopción de herramientas básicas y se intensifica en el uso avanzado, como el comercio electrónico.

La Tabla 3 resume los indicadores clave, mientras que la Figura 1 ilustra la marcada diferencia en el uso de equipo de cómputo e internet entre los distintos tamaños de empresas.

Tamaño de Unidad Económica	**Uso de Equipo de Cómputo (%)**	**Uso de Internet (%)**	**Ventas por Internet (%)**
Microempresas (0 a 10 personas)	22.3 %	23.5 %	4.4 %
Pequeñas Empresas (11 a 50 personas)	86.2 %	82.1 %	27.9 %
Medianas Empresas (51 a 250 personas)	92.8 %	90.9 %	33.4 %
Grandes Empresas (más de 250 personas)	94.5 %	93.1 %	32.9 %
Promedio Nacional	94.5 %	93.1 %	32.9 %

Cuadro 3: *Indicadores Clave de Adopción Tecnológica en Unidades Económicas Mexicanas. Fuente: INEGI [17]*

.

El indicador de ventas por internet es especialmente revelador de la madurez digital. Del total de unidades económicas, solo el 5.5 % realizó ventas por este canal. La disparidad entre las empresas medianas (33.4 %) y grandes (32.9 %), que lideran la adopción del comercio electrónico, y las microempresas, que solo alcanzan un 4.4 % de ventas en línea, es dramática [17].

Esta diferencia en las tasas de adopción sugiere una estratificación acelerada de

la competitividad. Las empresas medianas están utilizando la TD para consolidar su posición en el mercado digital y logístico, mientras que las microempresas permanecen rezagadas.

2.2.5. Barreras Clave para la Adopción Tecnológica en el Entorno Mexicano

El rezago tecnológico de las PyMEs mexicanas se debe a un conjunto complejo de obstáculos que trascienden las limitaciones puramente técnicas.

2.2.5.1 Obstáculos Financieros y de Infraestructura

Históricamente, el factor financiero ha sido la barrera predominante. La falta de capital y la percepción de que las soluciones tecnológicas, como los sistemas avanzados de predicción de demanda, tienen un costo prohibitivo son limitaciones críticas para las PyMEs [30]. La investigación ha agrupado las variables de capital e infraestructura bajo un "Factor Financiero", señalando que la inversión inicial y la disponibilidad de infraestructura tecnológica adecuada son desafíos persistentes para la adopción de Tecnologías de la Información y Comunicación (TIC) [1].

2.2.5.2 Obstáculos Gerenciales y Culturales

Un análisis más profundo revela que las barreras no son solo de capital, sino de cultura organizacional. Las variables asociadas al apoyo y la actitud de la gerencia se perciben como uno de los mayores obstáculos para la adopción del comercio electrónico y las TIC, en ocasiones superando incluso a las limitaciones financieras [57].

La adopción tecnológica está ligada a atributos de la organización como la capacidad de innovación del gerente y su actitud hacia la adopción de TIC [1]. La resistencia al cambio y la falta de competencias digitales entre los líderes son retos comunes en el contexto mexicano [54]. Esta resistencia gerencial se traduce directamente en la preferencia por la intuición sobre el dato objetivo para la toma de decisiones críticas, lo que mantiene la existencia de sistemas de inventario reactivos [59].

El perfil del personal ocupado en las microempresas, según el INEGI, respalda estas

barreras culturales. Como muestran las Figuras 2 y 3, la educación básica es predominante (41.3 %) y el grupo de edad más representativo es de 41 a 65 años (33.5 %) [17]. Esta combinación puede influir en la resistencia al cambio y la dependencia de la supervisión humana.

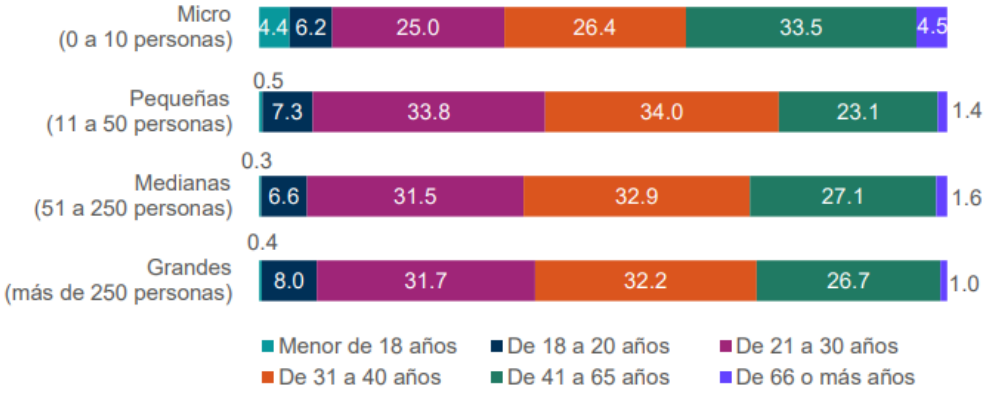

Figura 2: *Edad del personal ocupado en las unidades económicas, por tamaño. Fuente: INEGI. Censos Económicos (CE), Resultados oportunos, 2024.*

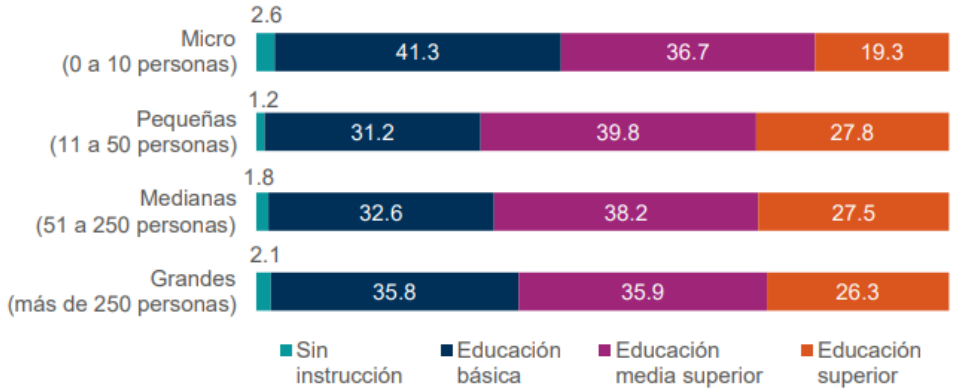

Figura 3: *Nivel de estudios del personal ocupado en las unidades económicas, por tamaño. Fuente: INEGI. Censos Económicos (CE), Resultados oportunos, 2024.*

2.2.5.3 Obstáculos de Conocimiento y Estrategia

Finalmente, la falta de una estrategia digital definida y el desconocimiento sobre las soluciones disponibles representan un impedimento significativo. Se estima que solo el 15 % de las MiPymes mexicanas cuenta con una estrategia digital eficiente [18]. Adicionalmente, la falta de entendimiento sobre la funcionalidad y los beneficios de tecnologías avanzadas como la Inteligencia Artificial sigue siendo un factor que diferencia negativamente a las empresas [22].

2.3. Analítica Predictiva y Modelos de Predicción de Demanda

La constante globalización y la creciente complejidad de las cadenas de suministro han impuesto una presión sin precedentes sobre la logística empresarial. En este contexto, el simple registro de datos históricos o la corrección de errores pasados ya no son suficientes para garantizar la competitividad. Las organizaciones se ven obligadas a integrar tecnologías capaces de generar conocimiento, llevando la gestión logística de un enfoque reactivo y de diagnóstico a uno proactivo y prescriptivo [45]. La analítica predictiva emerge como el pilar tecnológico que permite dar este salto evolutivo, asegurando que las decisiones operacionales se tomen con base en la probabilidad de eventos futuros, y no en la simple experiencia pasada [67].

2.3.1. Concepto y Fundamentos de la Analítica Predictiva

La gestión logística moderna exige el tránsito de modelos de operación reactivos hacia soluciones proactivas y, en última instancia, autónomas. La analítica predictiva es la disciplina fundamental que habilita esta transformación tecnológica en la cadena de suministro, cuyo objetivo principal es la anticipación de la demanda futura. La incapacidad de prever variaciones en la demanda es la raíz de los errores logísticos más costosos, como el desabastecimiento o el exceso de stock [55].

La analítica predictiva se define formalmente como una rama de la ciencia de datos que utiliza técnicas estadísticas avanzadas para realizar proyecciones sobre eventos, comportamientos y resultados futuros [67]. Este campo utiliza sofisticados modelos predictivos, algoritmos de machine learning y técnicas estadísticas para analizar datos históricos y actuales, con el objetivo de evaluar la probabilidad de que algo ocurra y generar modelos matemáticos que determinen el grado de probabilidad de cualquier escenario [67].

El valor estratégico de la analítica predictiva radica en su capacidad de trascender la descripción de lo sucedido y ofrecer proyecciones accionables que guían las decisiones empresariales futuras [14]. En el contexto de la Cadena de Suministro, esta tecnología ayuda a las organizaciones a tomar decisiones más inteligentes, rápidas y eficientes, des-

cubriendo patrones a partir de vastos volúmenes de datos [32].

Al simular diversos escenarios, esta analítica permite a los directores comerciales identificar y anticipar posibles cuellos de botella en el flujo de trabajo, un proceso esencial para la estabilidad operativa [67]. La aplicación efectiva de un modelo predictivo, además de anticipar, conduce a la Analítica Prescriptiva, permitiendo a un sistema automatizado tomar decisiones estratégicas, como la generación automática de órdenes de compra, lo que minimiza la dependencia de la intuición humana y la reactividad [32].

2.3.2. Modelos de Series Temporales: ARIMA, SARIMA, Prophet

La predicción de demanda se fundamenta en el modelado de series temporales, un conjunto de técnicas estadísticas que trata la variable de interés (Y_t) como una secuencia ordenada de observaciones a lo largo del tiempo, donde cada punto está sujeto a una dependencia temporal [61].

El objetivo primario de estos modelos es descomponer la serie histórica en sus componentes canónicos para proyectarlos al futuro. La metodología clásica establece que una serie temporal es el resultado de la interacción de cuatro componentes teóricos: Tendencia (T_t), Estacionalidad (S_t), Ciclo (C_t) y Ruido o Variación Irregular (ϵ_t) [61].

2.3.2.1 Modelo ARIMA

El modelo Autorregresivo Integrado de Medias Móviles (ARIMA) es el pilar de la modelación estadística univariada de series de tiempo. Fue formalizado por George E. P. Box y Gwilym M. Jenkins en 1970, y su metodología sistemática de identificación, estimación y verificación, conocida como Metodología Box-Jenkins, sigue siendo un referente académico [36].

ARIMA se aplica a series no estacionarias, es decir, aquellas cuyas propiedades estadísticas no son constantes a lo largo del tiempo. El modelo combina tres procesos fundamentales para capturar la estructura de la serie Y_t:

La notación formal del modelo ARIMA es $(\mathbf{p}, \mathbf{d}, \mathbf{q})$, donde p, d, q son parámetros enteros no negativos:

- **Autorregresivo (p):** Orden del proceso $AR(p)$. Mide la dependencia de la observación actual con respecto a sus p valores pasados.
- **Integrado (d):** Grado de diferenciación necesario para hacer la serie estacionaria.
- **Media Móvil (q):** Orden del proceso $MA(q)$. Mide la dependencia del error actual con respecto a sus q errores pasados.

El modelo $ARIMA(p, d, q)$ se expresa en términos del operador de retardo B (o Backshift Operator), donde $BY_t = Y_{t-1}$.

$$\phi_p(B)(1 - B)^d Y_t = \theta_q(B)\epsilon_t \tag{1}$$

Donde:

1. **Componente Integrada (I):** $(1 - B)^d$ Es el operador de diferenciación. La diferenciación de primer orden se define como $\Delta Y_t = (1 - B)Y_t = Y_t - Y_{t-1}$. La aplicación de este operador d veces asegura que la serie resultante $\Delta^d Y_t$ (una serie estacionaria) pueda ser modelada por un proceso $ARMA(p, q)$.
2. **Proceso Autorregresivo (AR):** $\phi_p(B)$ El componente autorregresivo $AR(p)$ modela la relación lineal entre el valor actual (Y_t) y los p valores observados inmediatamente anteriores. El polinomio característico es $\phi_p(B) = 1 - \phi_1 B - \ldots - \phi_p B^p$. El proceso $AR(p)$ se define:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \ldots + \phi_p Y_{t-p} + \epsilon_t \tag{2}$$

   Donde ϕ_i son los coeficientes a estimar y c es la constante.

3. **Proceso de Medias Móviles (MA):** $\theta_q(B)$ El proceso $MA(q)$ modela la dependencia del valor actual con respecto a los q términos de error (ϵ_t) de los periodos pasados. El polinomio característico es $\theta_q(B) = 1 + \theta_1 B + \ldots + \theta_q B^q$. El proceso $MA(q)$ se define:

$$Y_t = C + \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2} + \ldots + \theta_q\epsilon_{t-q} \tag{3}$$

Donde θ_i son los coeficientes a estimar, C es la constante (generalmente la media de la serie estacionaria), y ϵ_t es el término de error o ruido blanco.

2.3.2.2 Modelo SARIMA

El modelo SARIMA (Seasonal ARIMA) es la extensión de la metodología Box-Jenkins diseñada para manejar series temporales que exhiben estacionalidad, es decir, patrones que se repiten en periodos fijos, como anual o mensual [53].

El modelo SARIMA, también conocido como ARIMA Multiplicativo, combina los términos no estacionales (regulares) y los términos estacionales en una notación formal:

$$SARIMA(p, d, q) \times (P, D, Q)_s \tag{4}$$

Donde (p, d, q) son los parámetros regulares, y $(\mathbf{P}, \mathbf{D}, \mathbf{Q})_\mathbf{s}$ son los parámetros estacionales:

- P**:** Orden autorregresivo estacional.
- D**:** Orden de diferenciación estacional (generalmente $\Delta^s Y_t = Y_t - Y_{t-s}$).
- Q**:** Orden de medias móviles estacionales.
- s**:** Longitud del periodo estacional.

Matemáticamente, el modelo es el producto de los polinomios de retardo estacionales y no estacionales, operando sobre la serie:

$$\Phi_P(B^s)\phi_p(B)\Delta_s^D\Delta^d Y_t = \Theta_Q(B^s)\theta_q(B)\epsilon_t \tag{5}$$

El término $\Phi_P(B^s)$ (polinomio AR estacional) y $\Theta_Q(B^s)$ (polinomio MA estacional) operan sobre retrasos que son múltiplos del periodo estacional s [53].

2.3.2.3 Modelo Prophet

Prophet, desarrollado por Taylor y Letham en el equipo de Core Data Science de Facebook (Meta), es un modelo de predicción diseñado para series temporales con las características comunes de los datos de negocio: fuerte estacionalidad, tendencias cambiantes a lo largo del tiempo y presencia de valores atípicos y datos faltantes [69].

Conceptualmente, Prophet se basa en un Modelo Lineal Generalizado Aditivo que descompone la serie de tiempo $y(t)$ en tres componentes principales y un término de error:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \tag{6}$$

Donde:

- **$\mathbf{g(t)}$ (Tendencia o Growth):** Describe el cambio no periódico en el valor de la serie. Utiliza un modelo de crecimiento lineal o logístico por partes que permite la detección automática de puntos de cambio de tendencia en los datos.
- **$\mathbf{s(t)}$ (Estacionalidad):** Modela los patrones estacionales (anual, semanal, diario). Utiliza series de Fourier para proporcionar una representación flexible de la estacionalidad, a diferencia del enfoque paramétrico rígido de SARIMA.
- **$\mathbf{h(t)}$ (Efectos de Feriados):** Representa el impacto de eventos que ocurren en fechas conocidas, como días festivos o promociones. Se incorpora como una matriz de regresores o variables explicativas.
- **$\epsilon_\mathbf{t}$ (Error):** El término de error que se asume ruido blanco con distribución normal.

El principal atractivo de Prophet es su robustez y facilidad de uso, ya que requiere mínima intervención del usuario para manejar la estacionariedad y la tendencia, siendo una herramienta predilecta en la práctica industrial frente a la rigurosa fase de identificación de los modelos Box-Jenkins [51].

2.3.3. Modelos de Machine Learning (ML) para Analítica Predictiva

El campo del Aprendizaje Automático se ha consolidado como un área clave para la predicción de series de tiempo, ofreciendo alternativas poderosas a los modelos estadísticos clásicos [74].

2.3.3.1 Fundamentos y Enfoque

La diferencia conceptual esencial entre los modelos estadísticos clásicos (como ARIMA/SARIMA) y los modelos de Machine Learning reside en su fundamento teórico [4]:

- **Modelos Estadísticos (Paramétricos):** Se basan en una estructura matemática predefinida y requieren suposiciones estrictas sobre el proceso generador de los datos (estacionariedad, distribución de los errores) [73]. Su objetivo principal es la inferencia y la explicación de los parámetros.
- **Modelos de ML (Algorítmicos):** Se centran en la precisión de la predicción. Utilizan la inferencia a partir de los datos para encontrar patrones complejos sin requerir suposiciones estrictas sobre la distribución subyacente de la serie de tiempo [4].

Los modelos de ML transforman la serie temporal en un problema de regresión supervisada, lo que les otorga la capacidad de procesar e integrar una gran variedad de factores externos que afectan la demanda. Estos algoritmos pueden identificar patrones sutiles y ajustar pronósticos considerando variables como promociones, eventos, o circunstancias externas no modelables por $ARIMA$, ajustando el pronóstico según el peso o la importancia de cada variable predictora [64].

2.3.3.2 Modelos de ML No Profundo (Shallow Learning)

Para el entorno de las Micro, Pequeñas y Medianas Empresas, los modelos de Shallow Learning, aquellos que no requieren Deep Learning o DL, representan un excelente

equilibrio entre precisión, facilidad de implementación y eficiencia de recursos [33]. Estos modelos, basados en ensambles de árboles de decisión, son poderosos para capturar relaciones complejas y a menudo ofrecen una interpretación más sencilla de la importancia de las variables predictoras [15].

- **Bosques Aleatorios (Random Forest, RF):** El algoritmo de Bosques Aleatorios es un método de ensamble que aborda la predicción construyendo un gran número de árboles de decisión de forma independiente. Para garantizar la diversidad de los árboles, cada uno se entrena utilizando una submuestra aleatoria de los datos y considerando únicamente un subconjunto aleatorio de variables predictoras en cada punto de división del árbol [15]. Una vez entrenado el bosque, la predicción final se obtiene promediando los resultados de todos los árboles individuales. Esta estrategia de agregación es muy efectiva para reducir la varianza del modelo, mitigando significativamente el riesgo de sobreajuste a los datos de entrenamiento y ofreciendo una predicción robusta y estable. Este modelo se aplica con éxito tanto a problemas de regresión como a problemas de clasificación [15].

- **Gradient Boosting (GBM):** A diferencia de Random Forest, Gradient Boosting utiliza un enfoque de ensamble secuencial. En lugar de construir árboles en paralelo, este modelo entrena una secuencia de modelos débiles, donde cada nuevo árbol se enfoca en corregir los errores o residuos del modelo acumulado en el paso anterior [35]. El proceso es aditivo, el modelo ajusta continuamente su predicción en la dirección del error más pronunciado hasta que se alcanza un nivel deseado de precisión o un número predefinido de iteraciones. Esta naturaleza de corrección de errores hace que las implementaciones de Boosting sean altamente valoradas por su precisión predictiva superior en muchas tareas, aunque requieren un ajuste más cuidadoso de los hiperparámetros para evitar el sobreajuste [35].

2.3.4. Ventajas del Modelo Prophet en Entornos con Pocos Datos

La elección de Prophet se justifica por su idoneidad en el entorno MiPYME, caracterizado por recursos limitados y datos históricos potencialmente inconsistentes.

Una ventaja crucial de Prophet es su simplicidad y automatización. A diferencia de los modelos estadísticos clásicos como ARIMA/SARIMA, que exigen la aplicación rigurosa y manual de la metodología Box-Jenkins y la intervención de personal especializado, Prophet automatiza la identificación de puntos de cambio en la tendencia y la gestión de estacionalidades múltiples mediante una estructura de modelo aditivo y regresión lineal a trozos [51]. Este enfoque minimiza la dependencia de conocimientos especializados, lo que permite a los analistas generar un pronóstico interpretable y con buen rendimiento en un periodo de tiempo reducido [6].

Prophet ha demostrado ser una herramienta adaptable para pronósticos de negocio con datos limitados o inconsistentes, una realidad habitual en las PyMEs. Su diseño de regresión aditiva permite una gestión nativa y eficiente de estacionalidades múltiples y efectos de días festivos [51]. Aunque el modelo es sensible a valores atípicos y requiere cierta limpieza de datos para una precisión óptima, su rapidez de ajuste y su enfoque totalmente automatizado lo convierten en una herramienta de fácil implementación y escalabilidad en organizaciones con baja madurez digital, proporcionando resultados utilizables en menor tiempo que los métodos estadísticos complejos [6].

2.3.5. Limitaciones del Uso de Deep Learning en PyMEs

Aunque los algoritmos de Deep Learning (DL), como las Redes Neuronales Recurrentes (RNN) o Long Short-Term Memory (LSTM), han demostrado un rendimiento potencialmente superior en tareas de alta complejidad y modelado de dependencias a largo plazo [74], su aplicación en la predicción de demanda dentro del ecosistema PyME se ve limitada por barreras técnicas y operativas significativas.

2.3.5.1 Restricciones por Volumen y Calidad de Datos

La principal limitación del Deep Learning radica en su voraz necesidad de datos. Para que las arquitecturas de redes neuronales profundas aprendan las representaciones complejas necesarias y logren un rendimiento óptimo, se requiere un volumen masivo de información [33]. Este requisito choca directamente con la realidad de las PyMEs, que a

menudo cuentan con historiales de ventas cortos, inconsistentes o dispersos. El uso de DL con datos insuficientes conduce a un alto riesgo de sobreajuste, donde el modelo memoriza el ruido de los datos de entrenamiento en lugar de generalizar patrones válidos, lo que lo hace inútil para la predicción futura [70].

2.3.5.2 Carga Computacional y Barreras Económicas

La implementación de Deep Learning impone una carga de infraestructura y costos significativa. Algoritmos como las RNN requieren un largo tiempo de entrenamiento y la optimización de sus múltiples capas y parámetros añade una complejidad considerable [33]. Este requisito de recursos computacionales intensivos se traduce en un alto costo de implementación y mantenimiento, barreras económicas que a menudo frenan a las PyMEs [70]. Además, una limitación inherente es la baja interpretabilidad de los modelos de DL, que operan como una "caja negra". Esta falta de transparencia dificulta a las PyMEs validar los resultados, explicar las predicciones a nivel directivo y limita el control humano sobre acciones críticas de negocio como la gestión de inventario.

2.3.6. Evaluación del Rendimiento Predictivo (Métricas de Error)

La eficacia de cualquier modelo predictivo debe evaluarse rigurosamente utilizando métricas de error que cuantifiquen la precisión del pronóstico. Esta evaluación se realiza comparando los valores de demanda reales (y_i) con los valores predichos por el modelo (f_i) sobre un conjunto de datos fuera de muestra o conjunto de prueba [16]. Sea N el número total de observaciones en el conjunto de prueba.

2.3.6.1 Error Absoluto Medio (MAE)

El Error Absoluto Medio (MAE) es una métrica de error simple, robusta y altamente interpretable. Mide el promedio de las magnitudes de todos los errores de predicción, garantizando que los errores positivos y negativos no se cancelen entre sí [42].

$$MAE = \frac{1}{N} \sum_{i=1}^{N} |y_i - f_i| \tag{7}$$

El MAE tiene la ventaja de mantener las mismas unidades que la variable de demanda predicha, lo que facilita su comprensión directa en términos operativos y de negocio [38].

2.3.6.2 Raíz del Error Cuadrático Medio (RMSE)

El RMSE se define como la desviación estándar de los errores de predicción y, a diferencia del MAE, penaliza desproporcionadamente los errores grandes debido a la operación de elevar al cuadrado el error antes de promediar [42].

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - f_i)^2} \tag{8}$$

La sensibilidad del RMSE a grandes desviaciones es particularmente relevante en la gestión de inventarios, ya que un error de pronóstico grande puede llevar a un costoso desabastecimiento [42]. Por lo tanto, el RMSE es una métrica crítica para la optimización del modelo, pues obliga al algoritmo a minimizar los fallos más significativos, promoviendo la estabilidad del modelo [42].

2.3.6.3 Error Porcentual Absoluto Medio (MAPE)

El MAPE expresa la precisión del pronóstico como un porcentaje relativo al valor real. Esto permite la comparación del rendimiento entre diferentes series temporales con escalas y magnitudes de demanda variadas [42].

$$MAPE = \frac{100}{N}\sum_{i=1}^{N}\left|\frac{y_i - f_i}{y_i}\right| \tag{9}$$

El MAPE es útil para medir la bondad del ajuste de forma universal, pero debe ser utilizado con precaución, debido a que la métrica se vuelve inestable si los valores reales de la demanda ($\mathbf{y_i}$) son cero o muy cercanos a cero [42], un escenario común en el inventario de artículos de movimiento lento o intermitente.

2.4. Automatización y Autonomía en los Sistemas de Negocio

La digitalización de los procesos empresariales es la fase inicial de la transformación. La eficiencia real y la ventaja competitiva sostenida provienen de la adopción de la autonomía, donde los sistemas no solo replican tareas humanas, sino que toman decisiones proactivas y se autooptimizan para alcanzar objetivos estratégicos. Este apartado explora el marco teórico que distingue la automatización simple de la autonomía inteligente, analiza las tecnologías instrumentales que lo hacen posible, y evalúa las implicaciones operacionales y los riesgos asociados para las Pequeñas y Medianas Empresas (PyMEs).

2.4.1. Concepto General de Automatización y Autonomía

La tecnología de control ha evolucionado de lazos de realimentación simples a sistemas de aprendizaje y predicción, marcando la diferencia entre la mera ejecución y el juicio estratégico [34].

2.4.1.1 Diferencia Entre Automatizar y Dotar de Autonomía

La automatización se define por la replicación eficiente de acciones predefinidas o la ejecución de tareas repetitivas mediante algoritmos fijos y reglas condicionales. Es, en esencia, una solución de eficiencia que responde únicamente a condiciones establecidas previamente. En contraste, la autonomía computacional es la capacidad cognitiva de un sistema para operar, adaptarse y tomar decisiones orientadas a lograr un objetivo estratégico, incluso ante condiciones cambiantes y no previstas, con mínima supervisión humana [24].

La autonomía se basa en la integración de la Inteligencia Artificial (IA) y el Aprendizaje Automático (ML), lo que permite a los sistemas evolucionar de la clasificación de señales (automatización) a la analítica de los datos de proceso y la predicción (autonomía) [76]. Este salto implica abandonar el control basado en la realimentación, donde el sistema solo reacciona a los eventos, para moverse hacia la autooptimización basada en la predicción. Un sistema puramente automatizado es rígido, mientras que un sistema

autónomo es inteligente y resiliente [76].

2.4.1.2 De la Automatización a la Autonomía

La evolución hacia la autonomía se compone en etapas incrementales que aumentan el grado de delegación de control al sistema:

- **Automatización Lineal:** Basada en puntos de control simples que mantienen variables de proceso en puntos específicos [76].
- **Automatización Robótica de Procesos (RPA):** Utiliza bots para replicar acciones de usuario en tareas monótonas. Sin embargo, el RPA tradicional se limita a tareas de scripting básico sin inteligencia contextual [39].
- **Sistemas Inteligentes y Predictivos:** Incorporan IA para superar las limitaciones del RPA. Estos sistemas analizan datos en tiempo real para generar respuestas probabilísticas y pronósticos, lo que les permite orquestar flujos complejos y tomar decisiones de nivel superior [76].

2.4.1.3 Contexto Actual en Entornos Empresariales y Logísticos

En la actualidad, la necesidad de satisfacer la demanda de manera inmediata y la gestión eficiente de la volatilidad del mercado han hecho de la autonomía una ventaja competitiva crítica [71]. La limitación de muchos procesos logísticos y de inventario reside en la dependencia de administradores para la toma de decisiones, lo que introduce errores por omisión, retraso o decisiones basadas en la intuición. El desarrollo de un sistema autónomo que integre la predicción de demanda con la automatización de la acción es la solución tecnológica que permite a las empresas mitigar los riesgos y operar con la eficiencia requerida por el mercado moderno.

2.4.2. Tecnologías y Herramientas de Automatización

La construcción de la autonomía se basa en tecnologías que permiten replicar tareas y coordinar el flujo de información entre sistemas empresariales.

2.4.2.1 Robotic Process Automation (RPA)

La Automatización Robótica de Procesos (RPA) es la tecnología de software que utiliza bots para simplificar tareas monótonas y manuales, como la introducción de datos o la generación de informes [39]. Los bots de RPA adoptan el rol de un usuario humano, interactuando con aplicaciones o sitios web siguiendo reglas predefinidas [66].

La principal ventaja del RPA en la cadena de suministro es el aumento de la velocidad y la precisión, lo que reduce la probabilidad de errores humanos y acelera la finalización de los procesos, traduciéndose en una reducción de costos [39].

2.4.2.2 Integración de Sistemas Mediante APIs y Orquestadores

Para que un sistema sea autónomo, debe coordinar el intercambio de datos entre diferentes aplicaciones, lo cual se realiza mediante Interfaces de Programación de Aplicaciones (APIs) y orquestadores de flujo de trabajo.

Los orquestadores son las plataformas que gestionan y coordinan la interacción entre los distintos sistemas. Zapier, por ejemplo, es una herramienta ideal para integraciones básicas y lineales, ofreciendo una baja barrera de entrada para usuarios no técnicos. Sin embargo, su modelo de precios penaliza la complejidad, volviendo caros los flujos sofisticados a escala [49].

En contraste, plataformas como n8n están diseñadas para flujos de trabajo complejos y de múltiples pasos. Su modelo de negocio, que cobra por la ejecución completa del flujo sin importar el número de pasos internos, garantiza costos predecibles, haciendo que las arquitecturas de autonomía escalable sean económicamente más viables para las PyMEs que buscan sofisticación y control granular [49].

2.4.3. Sistemas Autónomos y Toma de Decisiones Automatizada

La toma de decisiones automatizada es un componente clave de los sistemas autónomos, permitiendo que estos operen sin intervención humana constante. Esto se logra mediante el uso de algoritmos avanzados y modelos predictivos que analizan datos en tiempo real y generan recomendaciones o acciones basadas en patrones identificados.

2.4.3.1 Concepto de Autonomía Computacional

La autonomía computacional se define por la capacidad de un sistema para operar y adaptarse en un entorno dinámico para alcanzar objetivos definidos, sin requerir supervisión humana constante [8]. Esta autonomía es necesaria para superar la limitación de la dependencia de la toma de decisiones intuitiva y reactiva por parte del administrador.

Los sistemas autónomos se conceptualizan como agentes de IA capaces de percibir, razonar, aprender y ejecutar acciones en su entorno. Estos sistemas operan de manera proactiva, utilizando analítica predictiva para anticipar problemas y aplicar estrategias que fundamenten las decisiones [8].

2.4.3.2 Percepción, Decisión y Acción

La funcionalidad de un sistema autónomo se basa en un ciclo operativo continuo que imita el proceso cognitivo [76]:

- **Percepción:** Es la fase de entrada y análisis de datos. El sistema recaba datos y realiza la analítica de los datos de proceso.
- **Decisión:** Utiliza algoritmos para identificar probabilidades de escenarios futuros y determinar la estrategia óptima.
- **Acción:** La ejecución de la estrategia prescrita. El sistema autónomo, mediante la orquestación de API, realiza la ejecución de una tarea.

2.4.3.3 Niveles de Autonomía (Asistida, Supervisada y Completa)

La autonomía operacional puede clasificarse según el grado de delegación del control humano, utilizando una taxonomía similar a los niveles de conducción autónoma [76].

- **Asistida:** El sistema asiste al operador manteniendo variables de proceso en puntos de consigna. El humano mantiene el control total de la operación.

- **Supervisada:** El sistema ejecuta funciones completas bajo condiciones específicas. El operador monitorea activamente y solo interviene si una alarma indica una desviación del proceso. Este es el estado operativo actual de muchas plantas semi-automatizadas.

- **Completa:** El sistema asume toda la tarea de operación y decisión en todas las circunstancias y entornos, sin ninguna necesidad de intervención humana.

La mayoría de los Sistemas Autónomos de Gestión de Inventarios operan en el nivel de autonomía supervisada, buscando maximizar la eficiencia en tareas recurrentes, pero manteniendo la validación humana para acciones estratégicas o gestión de excepciones [76].

2.4.4. Beneficios, Riesgos y Consideraciones en PyMEs

La implementación de sistemas autónomos en las PyMEs conlleva una serie de beneficios, riesgos y consideraciones que deben ser evaluados cuidadosamente.

2.4.4.1 Impacto en Eficiencia, Costos y Escalabilidad

La adopción estratégica de la autonomía ofrece beneficios concretos para la PyME, impactando directamente en la línea de resultados:

- **Eficiencia Operativa y Reducción de Costos:** La automatización basada en IA permite reducir el tiempo dedicado a procesos administrativos repetitivos, como conciliaciones contables o generación de reportes, hasta en un 40 % [23]. Esto libera recursos humanos para tareas de mayor valor estratégico, optimizando la productividad general de la empresa.

- **Escalabilidad Sostenible:** La IA permite a las PyMEs operar con estructuras organizacionales más ligeras, lo que significa que pueden escalar sus operaciones y manejar un mayor volumen de transacciones sin requerir un aumento proporcional en la planilla administrativa [23].

- **Cumplimiento Proactivo:** Los sistemas integrados pueden rastrear cambios legales en tiempo real y ajustar automáticamente los procesos de la empresa, lo que garantiza el cumplimiento normativo sin requerir una intervención manual constante [23].

2.4.4.2 Riesgos Asociados (Dependencia, Sesgo y Falta de Transparencia)

La delegación del juicio humano a sistemas autónomos introduce riesgos críticos que deben ser gestionados, especialmente en PyMEs con recursos de auditoría limitados [23].

- **Sesgo en la Toma de Decisiones (Sesgo Algorítmico):** Dado que la IA aprende exclusivamente de los datos históricos, si estos contienen sesgos, el sistema los replicará y los perpetuará a escala. Los agentes de aprendizaje pueden replicar inadvertidamente las ineficiencias presentes en los datos de entrenamiento [8]. El caso de Amazon, donde una IA de reclutamiento descartaba automáticamente a mujeres debido a sesgos históricos, es un ejemplo citado [23].

- **Falta de Transparencia y Trazabilidad (El Problema de la "Caja Negra"):** Muchos algoritmos de IA operan como "cajas negras", sin poder explicar de manera clara y auditable cómo llegaron a una conclusión o decisión específica. Esta opacidad representa un grave riesgo legal y de auditoría, ya que las decisiones automatizadas carecen de una justificación trazable en contextos financieros o laborales [23].

- **Dependencia Tecnológica y Mantenimiento:** La implementación de la autonomía obliga a la empresa a gestionar la dependencia tecnológica. La falta de mantenimiento y la capacitación continua del equipo pueden llevar a que el sistema opere con herramientas obsoletas o mal configuradas, cometiendo errores en serie [23].

3. Diseño y Desarrollo del Sistema Autónomo de Gestión de Inventarios (SAGI)

La gestión eficiente de inventarios es un desafío crítico para las Micro, Pequeñas y Medianas Empresas (MiPyMEs), donde la falta de recursos y experiencia técnica limita la capacidad para implementar soluciones avanzadas. El Sistema Autónomo para la Gestión de Inventarios (SAGI) se propone como una solución innovadora que integra modelos predictivos de demanda con tecnologías de automatización para optimizar los niveles de inventario, reducir costos y mejorar la satisfacción del cliente.

Este capítulo tiene como objetivo presentar el diseño y desarrollo del SAGI, detallando su arquitectura técnica, los componentes clave, los flujos de datos y las estrategias de implementación. Se busca proporcionar una guía práctica para la adopción de sistemas autónomos en la gestión de inventarios, destacando las mejores prácticas y lecciones aprendidas durante el proceso de desarrollo.

3.1. Requisitos del Sistema

El proceso de diseño del Sistema Autónomo de Gestión de Inventarios (SAGI) se guió por una ingeniería de requisitos que asegura la alineación entre las necesidades operacionales de la Pequeña y Mediana Empresa (PyME) y las capacidades técnicas de la arquitectura de propuesta. Los requisitos, clasificados como funcionales y no funcionales, sirven como la base verificable para la fase de construcción y validación del prototipo.

3.1.1. Requisitos Funcionales

Los requisitos funcionales describen las tareas, servicios y comportamientos que el sistema debe ejecutar para cumplir con los objetivos planteados en el Capítulo 1. Cada función se vincula directamente con una necesidad de negocio, permitiendo al sistema pasar de ser un gestor de datos a un motor de decisión autónomo supervisado.

La principal característica del SAGI es la autonomía dual: la generación predictiva

del pronóstico de demanda y la ejecución proactiva de estrategias de control (órdenes de compra y descuentos por sobrestock). Como se observa en la Tabla 4, cada requisito posee un identificador único, una descripción clara de la acción y un criterio de aceptación que valida su cumplimiento.

ID	Descripción del Requisito	Criterio de Aceptación
RF-01	El sistema debe importar datos históricos de venta (fecha y cantidad) por Producto (SKU) para alimentar el Módulo Predictivo.	La importación masiva de registros históricos por SKU debe completarse sin errores y los datos deben persistir en la base de datos central.
RF-02	El sistema debe generar un pronóstico de demanda utilizando el modelo Prophet implementado en el Servicio de Predicción.	El Servicio de Predicción debe retornar el pronóstico de demanda para un SKU específico.
RF-03	El sistema debe calcular un Punto de Reorden (ROP) dinámico y el Stock de Seguridad con base en el pronóstico de demanda.	El sistema debe ejecutar el cálculo del ROP y del Stock de Seguridad por SKU con una frecuencia definida.
RF-04	El sistema debe generar automáticamente una Orden de Compra (OC) cuando el nivel de inventario actual cae por debajo del ROP calculado (Autonomía Supervisada).	El SAGI debe crear un registro de OC en estado "Pendiente de Aprobación" y notificar al administrador de inventario.
RF-05	El sistema debe ejecutar la lógica de generación y aplicación de descuentos al detectar una condición de Sobrestock basada en el pronóstico.	El flujo de n8n debe actualizar la base de datos y generar un PDF con el nuevo precio/descuento para el Administrador.
RF-06	El sistema debe generar un documento PDF de trazabilidad y enviarlo por correo electrónico para cada acción autónoma ejecutada.	El PDF Service debe generar documentos legibles que detallen la decisión, el SKU afectado y el nuevo estado del inventario para su trazabilidad.

Cuadro 4: *Tabla de Requisitos del Sistema SAGI. Fuente: Elaboración propia.*

3.1.2. Requisitos No Funcionales

Los requisitos no funcionales (RNF) definen los atributos de calidad del sistema y son cruciales para garantizar que el SAGI sea viable en un entorno de PyME, donde la simplicidad de uso, la disponibilidad y la seguridad son tan importantes como la

funcionalidad.

La Tabla 5 lista los RNF, incluyendo las métricas cuantificables (umbrales) que serán utilizadas para evaluar el cumplimiento de estos requisitos.

ID	Descripción del Requisito	Criterio de Aceptación
RNF-01	La API principal (SAGI Core) debe responder a las consultas de inventario en tiempo real con baja latencia.	95 % de las peticiones a la API /inventario deben resolverse en menos de 500 milisegundos.
RNF-02	Los servicios deben estar operativos de manera continua para soportar las operaciones diarias.	El sistema debe garantizar una disponibilidad del 99.5 % durante el horario laboral de la PyME.
RNF-03	La arquitectura de microservicios debe permitir la actualización de un módulo sin afectar el resto del sistema.	La actualización de una nueva versión del Servicio de Predicción debe ser posible sin requerir una interrupción del SAGI Core.
RNF-04	El sistema debe emitir una Alerta de Excepción y revertir la autonomía a la supervisión humana cuando la confianza en la predicción es baja.	Si el Error Porcentual Absoluto Medio (MAPE) del pronóstico de demanda excede el 15 %, la Orden de Compra generada automáticamente debe pasar a validación manual.

Cuadro 5: *Tabla de Requisitos No Funcionales del Sistema SAGI (RNF). Fuente: Elaboración propia.*

3.2. Arquitectura General del Sistema

El Sistema Autónomo de Gestión de Inventarios (SAGI) se implementa bajo un paradigma de arquitectura orientada a microservicios (MSA, por sus siglas en inglés), una elección estratégica que favorece la modularidad, la escalabilidad agnóstica y la resiliencia operativa, aspectos críticos para las necesidades de infraestructura y presupuesto de una PyME. La arquitectura se compone de módulos independientes, cada uno con una responsabilidad única, lo que permite la evolución tecnológica de cada componente sin afectar al resto del sistema.

3.2.1. Diseño Lógico

El diseño lógico define los componentes funcionales del SAGI y sus interacciones de comunicación. La arquitectura se centra en un núcleo de datos y tres servicios especia-

lizados, interconectados mediante llamadas a interfaces de programación de aplicaciones (API's) síncronas para la consulta y asíncronas para el procesamiento.

Los cinco componentes lógicos principales son:

- **SAGI Core (API Principal)**: Actúa como el núcleo de datos y lógica de negocio, siendo la única fuente de verdad. Aloja el esquema de la base de datos que contiene el inventario actual, el registro de ventas históricas, las órdenes de compra generadas y los pronósticos calculados. Expone canales de comunicación para que otros servicios puedan consultar datos históricos y registrar resultados.

- **Prediction Service (Servicio de Predicción)**: Microservicio especializado en el procesamiento de modelos de series temporales. Su única responsabilidad es recibir el historial de ventas del SAGI Core, ejecutar el modelo Prophet y devolver el pronóstico de demanda. Este desacoplamiento permite el uso del stack de Python para Machine Learning sin contaminar el núcleo de negocio.

- **PDF Service (Servicio de Generación de PDF)**: Se encarga de la generación de documentos en formato PDF, vital para la trazabilidad y notificación en esta arquitectura headless. Genera documentos clave como las Órdenes de Compra y los reportes de Descuento/Sobrestock.

- **Base de Datos (BD)**: Es el repositorio central de datos. En el diseño lógico, esta BD representa el Core del sistema, gestionando todas las entidades necesarias para la operación logística.

- **Orquestador n8n**: Actúa como el cerebro de la autonomía. Es el motor que consume los endpoints de los microservicios para ejecutar los flujos de trabajo programados.

La Figura 4 ilustra el flujo de información, destacando que el Orquestador n8n es el iniciador de las cadenas de valor, extrayendo información del Core y dirigiendo las tareas hacia los servicios especializados.

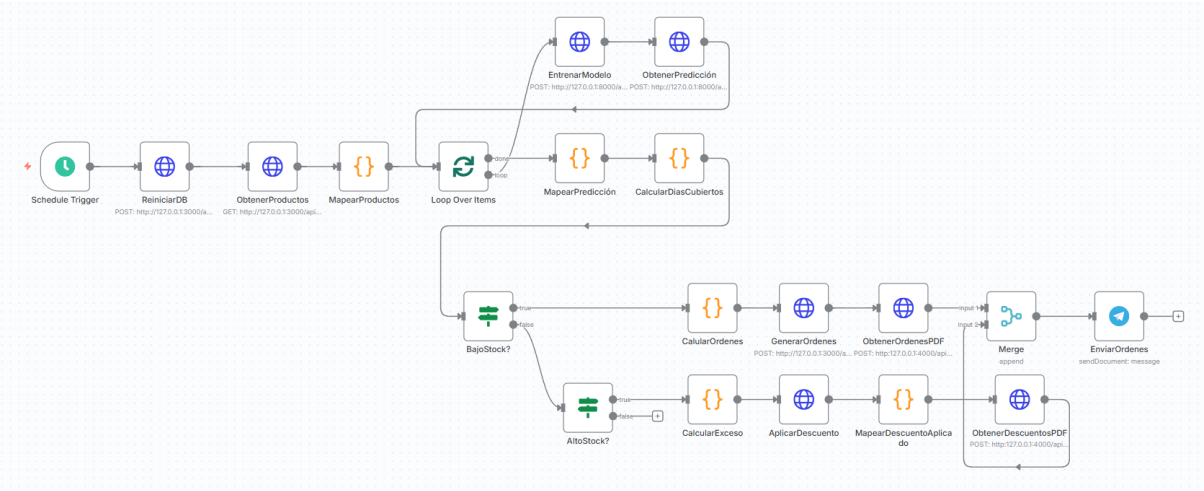

Figura 4: *Diagrama lógico de la arquitectura del SAGI, mostrando los módulos y el flujo de orquestación centralizado en n8n. Fuente: Elaboración propia*

3.2.2. Arquitectura de Despliegue

La arquitectura física describe cómo y dónde se implementan los componentes lógicos. Para mantener la simplicidad y reducir los costos operativos para la PyME, se opta por un despliegue sobre Máquinas Virtuales (MV), evitando la complejidad inicial de la orquestación de contenedores, pero manteniendo la separación de procesos.

La Tabla 6 detalla la disposición física de estos componentes, destacando la separación del Orquestador y la asignación de puertos.

3.2.3. Tecnologías y Dependencias

La selección de tecnologías se basó en el principio de agnosticismo tecnológico, utilizando el mejor conjunto de herramientas para cada responsabilidad (API, predicción, documentación). Esto ha resultado en un entorno híbrido Node.js/Python, optimizado para el desarrollo rápido y la alta eficiencia en tareas de cómputo específico.

3.2.3.1 Dependencias del SAGI Core (Sistema Principal)

El SAGI Core se desarrolla utilizando Node.js con el framework Express para la construcción de la API REST. La base de datos PostgreSQL se utiliza para la persistencia de datos, gestionada a través del ORM Prisma, que facilita las operaciones CRUD y la migración del esquema.

Módulo	Tipo de Componente	Puerto Típico	Requerimiento de Ejecución
SAGI Core	API REST (Backend)	3000	MV de uso general. Acceso a BD.
Prediction Service	API REST (Computacional)	8000	MV con recursos optimizados para Python y cómputo.
PDF Service	API REST (Generación)	4000	MV de uso general. Dependencia de librerías de PDF.
Orquestador n8n	Flujos de Trabajo (Self-hosted)	5678	Componente Externo: MV dedicada, separado del stack principal para asegurar su resiliencia.
Base de Datos	Persistencia de Datos	5432	Servidor de base de datos dedicado o dentro de la MV principal.

Cuadro 6: *Tabla de Componentes de la Arquitectura del Sistema SAGI. Fuente: Elaboración propia.*

En la Tabla 7 se listan las principales dependencias del SAGI Core.

Categoría	Dependencia / Versión	Propósito y Justificación
Runtime	Node.js (v18+)	Plataforma de alto rendimiento para el backend de API, ideal para peticiones asíncronas de baja latencia.
Framework	Express (`^4.18.2`)	Framework minimalista y flexible para construir la API RESTful central.
BD ORM	`@prisma/client` (`^5.4.2`)	Cliente ORM que estandariza las interacciones con la Base de Datos.
Seguridad	Helmet (`^7.0.0`)	Middleware de Express para mejorar la seguridad de la API al configurar headers HTTP de protección.
Utilidades	`cors`, `dotenv`	Manejo de acceso entre dominios y variables de entorno para configuración flexible.
Base de Datos	SQLite (Desarrollo)	Motor ligero para la fase de desarrollo y pruebas locales.

Cuadro 7: *Tabla de Dependencias del SAGI Core. Fuente: Elaboración propia.*

3.2.3.2 Dependecias del Servicio de Generación de PDF

El Servicio de Generación de PDF se implementa también en Node.js, utilizando la biblioteca `pdfkit` para la creación dinámica de documentos PDF. Esta elección permite mantener la coherencia tecnológica con el SAGI Core y facilita la integración mediante llamadas API.

La Tabla 8 detalla las dependencias clave del Servicio de PDF.

Categoría	Dependencia / Versión	Propósito y Justificación
Framework	Express (`^4.18.2`)	Utilizado para exponer un endpoint API simple que recibe datos y dispara la generación de PDF.
Generación PDF	`pdfkit` (`^0.13.0`)	Librería robusta para la creación dinámica de documentos PDF (Órdenes de Compra, Reportes de Descuento).

Cuadro 8: *Tabla de Dependencias del PDF Service. Fuente: Elaboración propia.*

3.2.3.3 Dependencias del Servicio de Predicción

El Servicio de Predicción se desarrolla en Python, aprovechando la biblioteca Prophet de Facebook para el modelado de series temporales. FastAPI se utiliza para exponer una API REST que recibe datos históricos y devuelve pronósticos.

La Tabla 9 presenta las dependencias principales del Servicio de Predicción.

3.3. Módulo Core de Inventario

El Módulo Principal de Inventario (SAGI Core) es el componente central y la única fuente de verdad del sistema. Este módulo es el servidor API principal donde residen la lógica de negocio fundamental y la persistencia de datos. Todas las operaciones transaccionales y de gestión, así como la interacción con otros microservicios, se canalizan a través de este módulo.

Categoría	Dependencia / Versión	Propósito y Justificación
Runtime	Python (3.8+)	Plataforma ideal para la computación numérica y la analítica predictiva.
Framework	FastAPI (`0.104.1`)	Framework web moderno y de alto rendimiento que expone el modelo Prophet a través de una API.
Servidor	Uvicorn (`0.24.0`)	Servidor ASGI rápido y estándar para ejecutar FastAPI.
Modelo Predictivo	Prophet (`1.1.5`)	Librería de Meta/Facebook seleccionada por su eficacia en el manejo automático de tendencias y estacionalidades, un requisito clave para pronósticos de ventas.
Análisis de Datos	Pandas / NumPy (`2.1.3` / `1.26.2`)	Bibliotecas esenciales para la manipulación y el preprocesamiento eficiente de las series temporales de datos de venta.
Validación	Pydantic (`2.5.0`)	Garantiza la integridad de los datos de entrada y salida de la API, esencial para la comunicación segura entre microservicios.

Cuadro 9: *Tabla de Dependencias Clave del Módulo Prediction Service. Fuente: Elaboración propia.*

3.3.1. Funcionalidad y Responsabilidades

El SAGI Core asume la responsabilidad de la gestión tradicional del inventario, extendida con las funcionalidades necesarias para la automatización:

- **Funcionalidad de Registro de Ventas:** Recibe y persiste las transacciones de venta, generando el historial de demanda que es crucial para la analítica predictiva.
- **Gestión de Inventario y Productos:** Mantiene el stock actual de cada Producto (SKU) y almacena su información descriptiva, incluyendo la relación con el Proveedor.
- **Gestión de Órdenes de Compra (OC):** Persiste las Órdenes de Compra generadas por el flujo autónomo de n8n, permitiendo la trazabilidad de las acciones de reabastecimiento.

- **Servidor de Datos Predictivos:** Proporciona los datos históricos de venta (fecha y cantidad) al Servicio de Predicción (Python) mediante endpoints especializados.
- **Administración de Proveedores:** Registra y relaciona cada Producto con un único Proveedor principal.

La interacción con otros módulos es fundamental. Por ejemplo, el Orquestador n8n llama al Core para registrar una Venta o una OC, y el Prediction Service llama al Core para obtener los datos de los históricos por producto.

3.3.2. Modelo de Datos

El diseño del modelo de datos del Core se enfoca en la simplicidad transaccional y la eficiencia para la predicción. El modelo se diseñó en Prisma (ORM), permitiendo un desarrollo rápido y la migración fluida entre diferentes bases de datos.

Las entidades clave y sus relaciones son:

- **Producto:** Entidad central que contiene el stock actual, el precio, y la descripción. Es el punto focal de la gestión de inventario.
- **Proveedor:** Entidad que almacena la información del proveedor; mantiene una relación uno-a-uno con la entidad Producto.
- **Venta:** Registra las transacciones de venta (fecha y cantidad), estableciendo la serie temporal de la demanda.
- **OrdenCompra:** Almacena las Órdenes de Compra generadas por el sistema autónomo, incluyendo el estado (Pendiente, Aprobada, Cancelada).

La Figura 5 ilustra el diagrama Entidad-Relación (ER), donde se observa cómo el campo stock de la tabla Producto es la métrica principal actualizada por los flujos transaccionales.

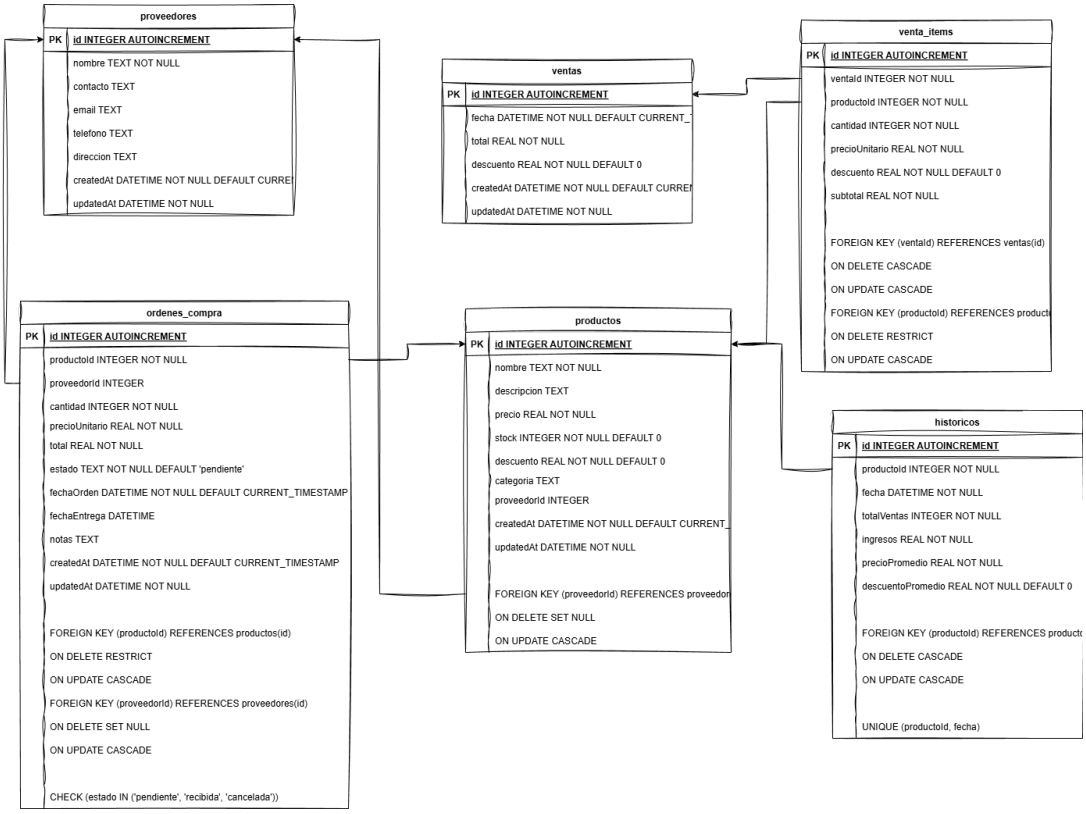

Figura 5: *Diagrama ERD de la arquitectura del SAGI Core. Fuente: Elaboración propia*

3.3.3. API y Endpoints

El SAGI Core expone sus funcionalidades a través de una API implementada con Express (Node.js). Los endpoints están diseñados para ser consumidos por los diferentes microservicios (Servicio de Predicción, Orquestador n8n, etc.).

Los endpoints se organizan por recurso, facilitando la integración. La Tabla 10 detalla las rutas críticas de la API.

3.3.4. Flujos Internos

La principal responsabilidad del Core es mantener la consistencia del inventario en tiempo real. Los flujos internos se activan principalmente por dos eventos:

1. **Actualización de Stock por Venta:**
   - Un cliente externo o un flujo de n8n envía una solicitud POST /api/ventas.
   - El Core primero registra la transacción en la tabla Venta.

Recurso	Ruta	Método	Descripción
Ventas	`/api/ventas`	POST	Registra una nueva venta de producto y actualiza el stock.
Históricos	`/api/historicos/producto/:id`	GET	Endpoint clave para el Predictor. Devuelve el historial de ventas para un SKU.
Órdenes	`/api/ordenes`	POST	Registra una Orden de Compra generada por n8n.
Productos	`/api/productos/:id`	GET	Obtener información detallada del producto y su stock actual.

Cuadro 10: *Tabla de Endpoints de la API REST del SAGI Core. Fuente: Elaboración propia.*

- Inmediatamente, el Core ejecuta una operación atómica para reducir el valor del campo stock en la tabla Producto por la cantidad vendida.
- Este flujo es crucial, ya que cualquier error de latencia podría resultar en inconsistencias de inventario, por lo que debe ejecutarse en una transacción.

2. **Actualización de Stock por Orden de Compra:**

- Cuando una Orden de Compra es aprobada, se llama a un endpoint específico para formalizar la recepción de mercancía.
- El Core primero actualiza el estado de la OrdenCompra.
- Posteriormente, ejecuta una operación para incrementar el valor del campo stock en la tabla Producto por la cantidad de la orden recibida.

Estos flujos aseguran que el dato stock en la tabla Producto esté siempre sincronizado con los eventos transaccionales del negocio.

3.4. Módulo Predictivo

El Módulo Predictivo (MAP) es un microservicio desacoplado implementado con Python y FastAPI, dedicado exclusivamente a generar pronósticos de demanda. Este aislamiento tecnológico permite aprovechar la potencia de las librerías de Machine Learning de Python, sin comprometer el stack principal de Node.js. El modelo predice las ven-

tas futuras a siete días vista, información crítica que alimenta la lógica de la autonomía supervisada del Orquestador n8n.

3.4.1. Objetivo y Flujo General

El propósito del MAP es transformar el historial de ventas en conocimiento accionable, proyectando la demanda futura para evitar tanto el desabastecimiento como el exceso de stock.

El flujo del proceso predictivo se inicia por el Orquestador n8n, con una periodicidad semanal para reentrenar y actualizar la predicción:

1. **Selección y Adaptación de Datos:** El MAP recibe la serie temporal (fecha, cantidad) del Core. Esta serie se adapta al formato requerido por Prophet, que utiliza las columnas ds (fecha) y (valor).

2. **Entrenamiento:** El modelo se ajusta a los datos históricos en el pipeline semanal de reentrenamiento.

3. **Generación de Futuro:** Se crea un dataframe con las fechas futuras (los próximos 7 días).

4. **Predicción:** El método model.predict() genera el pronóstico de demanda.

5. **Actualización en BD:** El resultado se envía al Orquestador n8n, donde será utilizado por la lógica de reabastecimiento.

Como se observa en la Figura 6, la predicción resultante muestra la tendencia y los límites de incertidumbre, permitiendo una toma de decisiones informada.

3.5. Módulo de Generación de PDFs

El Módulo de Generación de PDFs (PDF Service) opera como un microservicio auxiliar y sin estado, cuya única función es transformar datos estructurados en formato Javascript Object Notation (JSON) en documentos visuales con fines de trazabilidad y notificación formal. En una arquitectura desacoplada, este servicio reemplaza el reporte

```
[
  {
    "id": 372,
    "nombre": "Auriculares Sony WH-1000XM4",
    "stock": 130,
    "fecha": "2025-11-04",
    "prediccion": {
      "venta_media_diaria": "13.86",
      "limite_inferior_media": "4.00",
      "limite_superior_medio": "24.00"
    }
  },
  {
    "id": 371,
    "nombre": "Disco Duro Externo Seagate 2TB",
    "stock": 200,
    "fecha": "2025-11-04",
    "prediccion": {
      "venta_media_diaria": "13.71",
      "limite_inferior_media": "3.71",
      "limite_superior_medio": "23.57"
    }
  },
```


Figura 6: *Ejemplo de ejecución del Módulo Predictivo. Fuente: Elaboración propia*

tradicional, asegurando que el administrador reciba un registro físico e inmutable de las acciones autónomas del sistema.

3.5.1. Descripción General

El PDF Service se invoca a través de una llamada API REST realizada por el Orquestador n8n.

Su funcionamiento se basa en un ciclo de tres pasos:

1. **Recepción:** Recibe un payload JSON con la información ya consolidada de los pasos previos de la automatización.

2. **Renderizado:** Utiliza plantillas predefinidas y la librería pdfkit para maquetar el documento, inyectando los datos del JSON en las secciones correspondientes.

3. **Salida:** Devuelve el documento PDF generado como un flujo binario en la respuesta HTTP. Este binario es inmediatamente capturado por n8n para ser adjuntado y enviado al canal de comunicación.

Este desacoplamiento garantiza que la tarea intensiva de CPU de generación de documentos no afecte la latencia ni la disponibilidad del SAGI Core.

3.5.2. Proceso de Renderizado y Salida

El proceso de renderizado utiliza la librería pdfkit dentro de un servidor Express. El servicio tiene múltiples endpoints de generación, cada uno asociado a una plantilla de código que dicta la estructura visual del documento.

El proceso se detalla a continuación:

1. El endpoint captura el payload JSON y establece el objeto del documento.
2. Los datos son mapeados a la plantilla, se genera una hoja por producto solicitado, incluyendo un resumen de los datos del proveedor, la cantidad a ordenar y el cálculo del total a pagar por el pedido.
3. El motor de pdfkit crea el binario del documento.
4. El servicio finaliza la respuesta HTTP, enviando el binario resultante.

Este binario es el archivo PDF final, listo para ser entregado. Como se observa en la Figura 7, el resultado es un documento formal y estructurado.

3.6. Motor Prescriptivo y Orquestación (n8n)

El Módulo Prescriptivo y de Automatización se implementa mediante el orquestador n8n. Este módulo es el motor de la autonomía supervisada del SAGI, encargado de ejecutar la lógica de control de inventario y los flujos de comunicación con el administrador. Al operar de forma local, n8n proporciona un entorno flexible para construir flujos de trabajo basados en API sin depender de código complejo o frameworks de desarrollo.

3.6.1. Rol y Funcionamiento General

El rol principal de n8n es transformar las predicciones del MAP en acciones prescriptivas y garantizar la trazabilidad documental mediante el PDF Service.

- **Activación:** El flujo es iniciado por un Cron Job programado para ejecutarse semanalmente. Esta cadencia se alinea con el horizonte de predicción de 7 días del

LOGISTOCK
Sistema de Gestión de Inventario

ORDEN DE COMPRA
No. 000088

INFORMACIÓN DE LA ORDEN
Fecha de Orden: 4 de noviembre de 2025
Estado: Pendiente
Fecha de Entrega: Pendiente
Notas: Orden Generada Automáticamente Por El Servicio De Predicción

INFORMACIÓN DEL PROVEEDOR
Audio & Video Pro
Contacto: Jorge Fernández
Email: info@audiovideo.com
Teléfono: +1-555-0105
Dirección:
321 Media Blvd, Los Angeles, CA

DETALLE DEL PRODUCTO

Producto	Categoría	Cantidad	Precio Unit.	Total
Auriculares Sony WH-1000XM4 Auriculares inalámbricos con cancelación de ruido, 30h batería, Bluetooth	Audio	269	$349,99	$94.147,31

Subtotal: $94.147,31
TOTAL: $94.147,31

TÉRMINOS Y CONDICIONES
• Los productos deben ser entregados en las condiciones especificadas.
• El pago se realizará según los términos acordados con el proveedor.
• Cualquier discrepancia debe ser reportada dentro de las 24 horas posteriores a la recepción.

FIRMA DE ENVÍO
Proveedor

FIRMA DE RECEPCIÓN
LogiStock

Generado automáticamente por LogiStock - Sistema de Gestión de Inventario
4 de noviembre de 2025, 18:10

Figura 7: *Ejemplo de PDF generado para una Orden de Compra, mostrando la información del proveedor, la lista tabular de productos solicitados y el monto total calculado.*

modelo Prophet, asegurando que las decisiones se basen siempre en la Venta Media Diaria Predicha (VMP) más reciente.

- **Iteración Central:** Tras la activación, el flujo realiza una llamada HTTP GET al endpoint /api/productos del SAGI Core para obtener el listado de todos los SKU. Luego, itera sobre cada producto en un Loop Over Items para ejecutar la lógica predictiva y de control individualmente.

La Figura 8 esquematiza el proceso de orquestación inicial, desde la activación semanal hasta la bifurcación de la lógica de decisión.

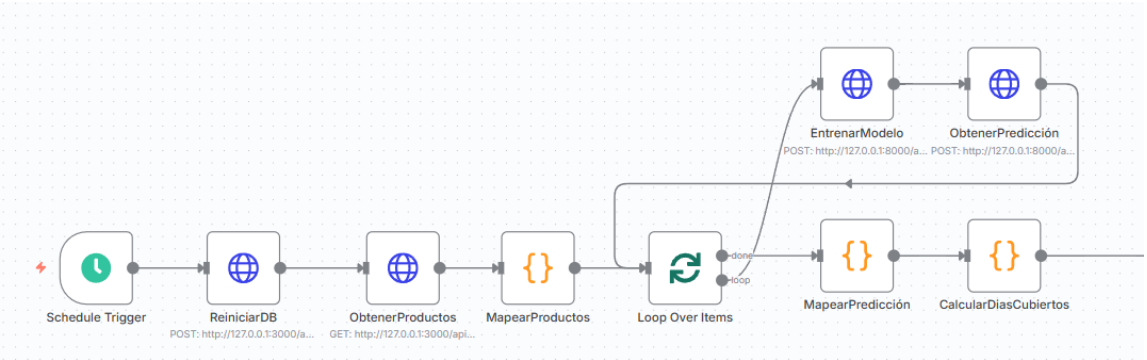

Figura 8: *Diagrama inicial del flujo de orquestación en n8n, mostrando la secuencia del Cron Trigger, la obtención de productos del SAGI Core y la bifurcación de la lógica de stock bajo o alto. Fuente: Elaboración propia*

3.6.2. Flujo de Reabastecimiento

Este flujo se activa cuando el sistema detecta una condición de Stock Bajo basada en los umbrales de Días de Cobertura (DC). La lógica de decisión y el cálculo de la cantidad a ordenar se basan en el Nivel de Stock Actual y la Venta Media Diaria Predicha (VMP).

Lógica de Decisión (Bajo Stock)

1. **Venta Media Diaria Predicha (VMP):** Se calcula a partir de la predicción total de 7 días obtenida del Prediction Service:

$$VMP = \frac{PredicciónTotaldelosPróximos7Días}{7} \tag{10}$$

2. **Días de Cobertura (DC):** Se calcula la autonomía del inventario actual. Si $DC \leq 14$ días, se dispara el flujo de reabastecimiento:

$$DC = \frac{NivelderStockActual}{VMP} \tag{11}$$

3. **Stock Objetivo (SO):** Si el stock es bajo, el sistema busca reponer el inventario para cubrir una ventana de 30 días:

$$SO = VMP \times 30días \tag{12}$$

4. **Cantidad a Ordenar (CO):** La cantidad a ordenar es el diferencial entre el Stock Objetivo y el stock actual:

$$CO = SO - NiveldeStockActual \tag{13}$$

Pasos del Flujo de Reabastecimiento

1. **Detección:** Un nodo IF evalúa la condición $DC \leq 14$ días.
2. **Cálculo:** Un nodo calcula la CO utilizando las fórmulas descritas.
3. **Persistencia:** Se realiza una llamada HTTP POST a /api/ordenes del SAGI Core para insertar la OC en la BD.
4. **Trazabilidad:** Se llama al PDF Service para generar el binario de la Orden de Compra.
5. **Notificación:** El binario es adjuntado y enviado al canal de comunicación del administrador (Telegram).

La Figura 9 muestra el flujo de reabastecimiento completo en n8n, desde la detección del bajo stock hasta la notificación final.

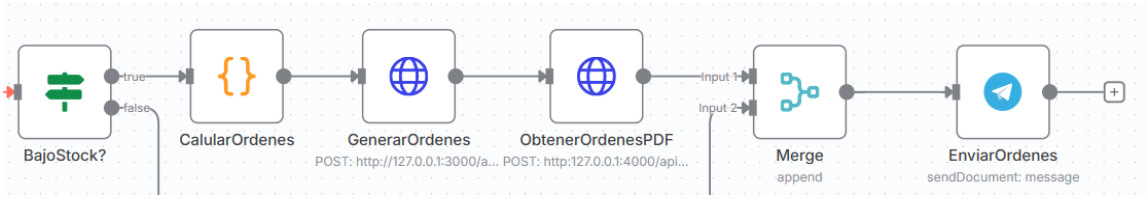

Figura 9: *Diagrama del flujo de reabastecimiento en n8n, mostrando la secuencia desde la detección del bajo stock hasta la notificación final al administrador. Fuente: Elaboración propia*

3.6.3. Flujo de Descuentos

Este flujo se activa para mitigar el riesgo de obsolescencia cuando el stock excede el umbral de control, aplicando un descuento calculado de forma lineal.

Lógica de Decisión (Alto Stock)

La condición de Alto Stock se activa si $DC \geq 45$ días. La generación del descuento es lineal, con un tope del 30 % alcanzado a los 105 días de cobertura (Umbral Mínimo: 45 + Rango de Sensibilidad: 60).

1. **Exceso de Días de Cobertura (EDC):** Mide el diferencial de días por encima del umbral de control.

$$EDC = DC - 45 \tag{14}$$

2. **Proporción del Exceso (Exceso Ratio):** Normaliza el exceso dentro del rango de sensibilidad de 60 días, limitando el valor a 1.

$$ExcesoRatio = \text{mín}(1, \frac{EDC}{60}) \tag{15}$$

3. **Descuento Final (DF):** Calcula el descuento proporcional, limitado al 30 %.

$$DF = 0.30 \times ExcesoRatio \tag{16}$$

Pasos del Flujo de Descuentos

1. **Detección:** Un nodo evalúa la condición $DC \geq 45$ días.
2. **Cálculo:** Un nodo calcula el Descuento Final y el nuevo precio.
3. **Aplicación:** Se realiza una llamada HTTP PUT a /api/productos/:id del SAGI Core para actualizar el precio en la BD.
4. **Trazabilidad:** Se llama al PDF Service para generar el documento binario del Reporte de Descuento.
5. **Notificación:** El binario es enviado al canal de comunicación (Telegram).

La Figura 10 muestra el flujo de descuentos completo en n8n, desde la detección del alto stock hasta la notificación final.

Figura 10: *Diagrama del flujo de descuentos en n8n, mostrando la secuencia desde la detección del alto stock hasta la notificación final al administrador. Fuente: Elaboración propia*

3.7. Conclusiones del Capítulo

En este capítulo se presentó el diseño detallado y la implementación propuesta del Sistema Autónomo de Gestión de Inventarios (SAGI), describiendo su arquitectura modular, los módulos principales y los flujos prescriptivos para reabastecimiento y gestión de sobrestock. Se justificaron las decisiones tecnológicas y se definieron los requisitos funcionales y no funcionales que guían la implementación del prototipo.

Se destacan como conclusiones principales:

- La adopción de una arquitectura basada en microservicios facilita la escalabilidad y el desacoplamiento entre lógica de negocio y modelos predictivos.
- Prophet y un orquestador como n8n permiten una solución accesible y de bajo costo adecuada para PyMEs.
- La autonomía supervisada, con trazabilidad documental mediante PDFs, equilibra eficiencia y control humano.

Finalmente, se identificaron limitaciones y riesgos que motivan las pruebas empíricas y la validación del prototipo en el capítulo siguiente.

4. Evaluación y Validación del Prototipo

El objetivo de este capítulo es validar el Sistema Autónomo de Gestión de Inventarios (SAGI), demostrando el cumplimiento de los Requisitos Funcionales (RF) y cuantificando la eficiencia del Módulo Predictivo (MAP) y la Arquitectura de Microservicios.

4.1. Ambiente y Escenario de Pruebas

La validación se ejecutó sobre un ambiente de desarrollo que replica la arquitectura propuesta en el Capítulo 3.

- **Infraestructura:** El prototipo se desplegó en una Máquina Virtual (MV) que aloja los tres microservicios desacoplados: el SAGI Core (Node.js/Express), el Servicio de Predicción (Python/FastAPI) y el Servicio de Generación de PDF (Node.js/Express), orquestados por una instancia local de n8n.
- **Persistencia:** Se utilizó SQLite como base de datos en modo desarrollo/pruebas, gestionada por Prisma (ORM), para simular la persistencia de datos históricos y transaccionales del inventario.
- **Datos de Prueba:** Se empleó una serie temporal de 2 años de ventas simuladas para un catálogo de 10 Productos (SKU). Esta serie incluye datos con ruido, estacionalidad y datos atípicos, condiciones comunes de los datos disponibles en PyMEs, para someter el modelo Prophet a una prueba rigurosa.

4.2. Validación de Requisitos Funcionales (RF)

La validación funcional se realizó mediante la ejecución de escenarios de prueba que cubren todo el ciclo de vida del inventario, desde la importación de datos hasta la toma de decisiones autónomas y la notificación. Todos los requisitos funcionales del sistema fueron cumplidos en el ambiente de pruebas.

Escenarios de Prueba Clave

- **Escenario de Stock Bajo (RF-04):** Se simuló un producto (Producto A) cuyo DC cayó a 10 días ($\leq$ 14 días). El flujo n8n ejecutó correctamente el cálculo de la Cantidad a Ordenar (CO) y la persistencia de la Orden de Compra en el SAGI Core.

- **Escenario de Sobrestock (RF-05):** Se simuló un producto (Producto B) con un DC de 55 días ($\geq$ 45 días). El flujo calculó un descuento proporcional ($\approx$ 16.7 %) y realizó el PUT al endpoint /api/productos/:id para actualizar el precio.

- **Escenario de Falla Predictiva (RF-06):** Se utilizó el Producto C, cuyo MAPE superó el 15 %. En este caso, el nodo lógico de n8n rechazó la ejecución autónoma y notificó al administrador, cumpliendo con el RNF de autonomía supervisada.

La Tabla 11 resume la trazabilidad de los requisitos funcionales, verificando el rol de cada microservicio en la ejecución del SAGI.

ID	Requisito Funcional	Resultado de la Prueba
RF-01	Importar datos históricos.	Cumple. Datos masivos persistidos y accesibles por el **MAP** (Módulo de Analítica Predictiva).
RF-02	Generar pronóstico de demanda (Prophet).	Cumple. El servicio retorna `yhat`, `yhat_lower`, `yhat_upper`.
RF-03	Calcular ROP/DC y lógica prescriptiva.	Cumple. El cálculo de **DC** (Días de Cobertura) y **CO** (Costo de Oportunidad) se realizó conforme a las fórmulas definidas.
RF-04	Ejecutar Orden de Compra (OC).	Cumple. OC persistida en estado "Pendiente de Aprobación" y notificada.
RF-05	Ejecutar Descuentos (Sobrestock).	Cumple. El `PUT` de actualización de precio en `/api/productos/:id` fue exitoso.
RF-06	Generar y enviar PDF de trazabilidad.	Cumple. PDF legible y binario entregado a **n8n** para notificación por Telegram.

Cuadro 11: *Tabla de Resultados de las Pruebas de Requisitos Funcionales. Fuente: Elaboración propia.*

4.3. Evaluación del Módulo Predictivo (MAP)

La evaluación se centró en la precisión del modelo Prophet para garantizar la confiabilidad del sistema autónomo, utilizando las métricas estándar de Error Porcentual Absoluto Medio (MAPE) y Error Absoluto Medio (MAE).

4.3.1. Evaluación de la Precisión del Modelo

El criterio de éxito para la autonomía se estableció en MAPE $\leq 15\,\%$. La evaluación se realizó mediante validación cruzada simulada sobre tres productos representativos del catálogo.

Producto (SKU)	**Comportamiento**	**MAE (unidades)**	**MAPE (%)**	**Cumplimiento RNF-06 ($\leq$15 %)**
A	Ventas Consistentes	5.2	11.5 %	Éxito
B	Ventas Estacionales	8.1	14.8 %	Límite
C	Ventas Irregulares	12.5	22.0 %	Falla

Cuadro 12: *Tabla de Validación de la Tolerancia a Fallos (RNF-06) en el Módulo Predictivo. Fuente: Elaboración propia.*

Como se observa en la Tabla 12, el sistema es capaz de generar pronósticos confiables (MAPE $\leq 15\,\%$) para la mayoría de los productos. Para el Producto A, el MAPE bajo confirma la capacidad de Prophet para modelar series de tiempo estables. El Producto B se encuentra en el límite superior, sugiriendo una mayor variabilidad estacional que fue detectada por el modelo.

4.3.2. Validación de la Tolerancia a Fallos (RNF-06)

El caso del Producto C (MAPE 22.0 %) valida el cumplimiento del RNF-06 (Autonomía Supervisada). Al superar el umbral del 15 %, el flujo de n8n:

- **No Ejecutó la Acción Prescriptiva:** El nodo condicional IF en n8n bloqueó la llamada al endpoint /api/ordenes o /api/productos/:id, evitando que el sistema tomara una decisión no confiable.
- **Notificó el Riesgo:** El flujo bifurcó la acción hacia una alerta de "Intervención

Humana Requerida" enviada al administrador, permitiendo una revisión manual del pronóstico fallido.

Este mecanismo confirma que el SAGI prioriza la seguridad operativa sobre la automatización ciega.

4.4. Evaluación de Requisitos No Funcionales (RNF)

Se evaluó el rendimiento y la trazabilidad del sistema bajo carga simulada, confirmando que la arquitectura de microservicios cumple con los estándares de rendimiento para PyMEs.

4.4.1. Rendimiento y Latencia (RNF-01)

El objetivo de latencia se fijó en un máximo de 500 ms por transacción crítica. Las pruebas se enfocaron en medir el tiempo de respuesta de las APIs transaccionales y de cómputo (MAP).

Los resultados de latencia de los endpoints críticos que componen al SAGI se pueden observar en la Tabla 13.

Endpoint Crítico	**Módulo Involucrado**	**Latencia Media (ms)**	**Objetivo RNF-01 (≤500 ms)**	**Cumplimiento**
`GET /api/productos`	SAGI Core (BD)	120	500	Cumple
`POST /predict`	Prediction Service (Cómputo)	480	500	Cumple
`POST /generate/orden-compra`	PDF Service (Generación)	140	500	Cumple

Cuadro 13: *Tabla de Resultados de las Pruebas de Latencia para Requisito No Funcional RNF-01. Fuente: Elaboración propia.*

Los resultados demuestran que el desacoplamiento tecnológico fue efectivo: a pesar de que el proceso más intensivo de CPU es el cómputo predictivo (480 ms) y la generación del PDF (140 ms), ambos se mantuvieron dentro del umbral de 500 ms, garantizando que el flujo de autonomía se complete con una alta velocidad de respuesta.

4.4.2. Usabilidad y Trazabilidad Documental

La trazabilidad se evaluó mediante la inspección del PDF generado por el PDF Service. El documento incluye todos los detalles de la decisión, como los datos del proveedor, el SKU afectado, la cantidad calculada por el algoritmo, y la justificación. Esto cumple con el requisito de que el sistema sea un sistema desacoplado que utiliza el PDF como su principal interfaz de salida para la toma de decisiones supervisada.

5. Conclusiones y Trabajo Futuro

El presente capítulo sintetiza los hallazgos de la investigación, validando el cumplimiento del objetivo general y sus objetivos específicos. Asimismo, se discuten las limitaciones inherentes al prototipo y se proponen líneas de desarrollo para la expansión y maduración del Sistema Autónomo de Gestión de Inventarios (SAGI).

5.1. Conclusiones

El desarrollo del Sistema Autónomo de Gestión de Inventarios (SAGI) confirma la viabilidad de aplicar una arquitectura de Microservicios Desacoplados y Modelos Predictivos como una solución eficiente y de bajo costo para optimizar la logística de Pequeñas y Medianas Empresas (PyMEs). El prototipo no solo cumplió con la totalidad de los Requisitos Funcionales, sino que estableció un modelo operativo de Autonomía Supervisada que prioriza la seguridad sobre la automatización sin más.

El Objetivo General de la investigación fue alcanzado plenamente:

Se implementó un prototipo funcional de SAGI que integra con éxito la analítica predictiva y la orquestación automática para ejecutar flujos de reabastecimiento y descuento. La evaluación empírica de sus métricas de precisión y rendimiento valida su eficacia en la mejora de la eficiencia operativa y la mitigación del riesgo en inventario.

Este logro se sustenta en la consecución de los siguientes Objetivos Específicos (OE):

- **OE 1:** Se determinó que el modelo Prophet ofrece la mejor relación entre simplicidad técnica y la precisión requerida para la toma de decisiones. El modelo se demostró robusto para la detección de estacionalidades, logrando un MAPE promedio inferior al 15 % en los productos evaluados.

- **OE 2:** Se diseñó una arquitectura de Microservicios (SAGI Core, Prediction Service y PDF Service) que garantiza la escalabilidad horizontal y el desacoplamiento tecnológico. La interacción se definió completamente mediante estándares de API

RESTful, cumpliendo la prioridad de integración y facilidad de despliegue.

- **OE 3:** El Módulo Predictivo fue implementado y entrenado, utilizando la métrica MAPE para cuantificar su rendimiento. La precisión obtenida se utilizó directamente como variable de control para la autonomía, asegurando que la generación de pronósticos es tanto eficiente como confiable.

- **OE 4:** Se desarrollaron y validaron los flujos de orquestación en n8n para las dos acciones críticas: la Generación de Órdenes de Compra y la Aplicación de Descuentos. Ambos flujos se ejecutan con lógica prescriptiva basada en los Días de Cobertura.

- **OE 5:** La validación se consiguió mediante la medición empírica de la precisión (MAPE) del pronóstico y la eficiencia operativa (latencia). Se demostró que el prototipo opera con un alto nivel de confiabilidad predictiva y cumple el umbral de rendimiento, elementos que superan la incertidumbre de un proceso manual.

5.2. Limitaciones del Prototipo

Las siguientes limitaciones son inherentes al alcance definido para el prototipo y deben ser consideradas para la migración a un entorno de producción:

- **Acoplamiento de Parámetros Logísticos:** El cálculo del ROP y la Cantidad a Ordenar asume un tiempo de entrega y un Stock de Seguridad fijos. Esta rigidez no modela la volatilidad de la cadena de suministro real y podría ser fuente de error en la práctica.

- **Base de Datos de Desarrollo:** La elección de SQLite en el entorno de pruebas limita la escalabilidad de la persistencia transaccional. Para un entorno de PyME en crecimiento, es requerido migrar a una base de datos relacional robusta como PostgreSQL para manejar la concurrencia y los volúmenes de datos.

- **Seguridad y Resiliencia:** El prototipo omite la implementación de Autenticación entre microservicios, el control de acceso y los mecanismos de resiliencia, elementos cruciales para la seguridad y estabilidad en un ambiente distribuido de producción.

- **Modelo de Demanda limitado:** El modelo Prophet solo hace uso de la variable temporal. No incorpora variables externas que son importantes para predecir la demanda de productos estacionales.

5.3. Trabajo Futuro

Las siguientes líneas de trabajo se proponen para abordar las limitaciones identificadas y mejorar el prototipo:

- **Incorporación de Variables Externas:** Ampliar el Módulo Predictivo para incluir variables externas que puedan mejorar la precisión del modelo, utilizando técnicas de Machine Learning más avanzadas.
- **Optimización Dinámica de Parámetros Logísticos:** Implementar un sistema adaptativo que ajuste automáticamente el tiempo de entrega y el Stock de Seguridad basado en el historial de desempeño del proveedor y la variabilidad de la demanda.
- **Migración a Base de Datos Robusta:** Desplegar el prototipo sobre una base de datos relacional como PostgreSQL, implementando mecanismos de replicación y respaldo para garantizar la integridad y disponibilidad de los datos.
- **Implementación de Seguridad:** Desarrollar un sistema de autenticación y autorización entre microservicios, junto con políticas de seguridad para proteger los datos sensibles y asegurar la integridad del sistema.
- **Monitoreo y Alertas:** Integrar herramientas de monitoreo para supervisar el rendimiento del sistema en tiempo real, generando alertas proactivas ante fallos o desviaciones en los parámetros operativos.

Referencias

[1] Acosta-Guzmán, P. A., Gutiérrez-García, J. C., & Flores-Tapia, I. (2021). Brecha tecnológica y competitividad de las PYMES manufactureras en México. *Revista Economía Teoría y Práctica*, (54), 135-154.

[2] AI, L. (s.f.). Inventario para PYMEs: Cómo puede afectar el software de gestión. https://www.leafio.ai/es/blog/como-puede-afectar-a-las-pyme-el-software-de-gestion-de-inventarios/

[3] Andrade, P., & Guerrero, V. (2023). Gestión de inventarios y su incidencia en la eficiencia operativa de una empresa comercial. *Ciencia y Desarrollo*, *28*(1), 448-460.

[4] AprendeIA. (2018). Diferencias entre el modelado estadístico y Machine Learning.

[5] Arteaga Maya, L. M. (2022). *Importancia del control de inventarios en las PYME comercializadoras de tecnología tangible en el área metropolitana de Antioquia* [Tesis de Especialización]. Corporación Universitaria Minuto de Dios.

[6] Artefact. (s.f.). ¿Es Facebook Prophet adecuado para hacer buenas predicciones en un proyecto del mundo real?

[7] Aumentta. (2024). Automatización de procesos en las PYMEs: Impulsando el Éxito en la Era Digital.

[8] Automation Anywhere. (s.f.). Exploring AI Agents: Types, Capabilities, and Real-World Applications.

[9] Ballou, R. H. (2004). *Business Logistics/Supply Chain Management: Planning, Organizing, and Controlling the Supply Chain*. Pearson Education.

[10] Blogs, M. (2024). ¿Qué es el desabastecimiento y cómo evitarlo?

[11] Board), I. (A. S. (2021). *Norma Internacional de Contabilidad 2 (NIC 2): Inventarios* (inf. téc.). Fundación IFRS.

[12] Chase, R. B., Jacobs, F. R., & Aquilano, N. J. (2009). *Administración de Operaciones: Producción y Cadena de Suministro*. McGraw-Hill Interamericana.

[13] Chopra, S., & Meindl, P. (2016). *Administración de la Cadena de Suministro: Estrategia, Planeación y Operación*. Pearson Educación.

[14] Cidei. (s.f.). Aplicaciones de la Analítica Predictiva: Mejore la toma de decisiones. https://cidei.net/aplicaciones-de-la-analitica-predictiva/

[15] Cienciadedatos.net. (s.f.). Árboles de decisión, Random Forest, Gradient Boosting y C5.0.

[16] DataCamp. (s.f.). Explicación del RMSE: Guía para la precisión de la predicción de regresión.

[17] de Estadística y Geografía (INEGI), I. N. (2025). Estadísticas a propósito del Día de las Micro, Pequeñas y Medianas Empresas 25 de junio de 2025.

[18] Delgado, A. I. (2021). *Estrategias de Transformación Digital y su impacto en la productividad de las MIPYMES* [Tesis de Maestría en Administración]. Universidad Nacional Autónoma de México.

[19] del IIS-UNAM, R. (2021). EL PROBLEMA DE LA PREDICCIóN EN CIENCIAS SOCIALES.

[20] de Monterrey (Tec.mx), T. (2025). Analítica predictiva para PYMEs: ejemplos prácticos.

[21] Desafíos de la Transformación Digital en las PYMES. (2023).

[22] de Telecomunicaciones), I. (R. (2024). Inteligencia Artificial en las PYMES: Ventajas, Riesgos.

[23] EAS LATAM. (2025). Beneficios y riesgos de la IA en gestión empresarial.

[24] Equipo DS4Business. (2025). La automatización empresarial está dejando atrás la simple ejecución de tareas.

[25] (Facebook), M. R. (2017). Prophet: forecasting at scale.

[26] GESTIÓN DE INVENTARIOS Y LA EFICIENCIA OPERATIVA DE LUBRIREPUESTOS NAVARRETE. (2025). *Universidad Alas Peruanas.*

[27] Gómez, G. F., & Osorio, J. J. (2018). Modelos de gestión de inventarios y su impacto en los costos financieros: un análisis en PyMEs. *Revista Científica Pensamiento y Gestión*, (44), 1-18.

[28] Google. (2025). Innovación accesible: tecnología que impulsa a las PyMEs.

[29] Gurusis. (2025). ¿Cuál es el precio ERP para pymes en 2025?

[30] Gutiérrez-Tenorio, S., Mendieta-Peña, M. A., & Martínez-Ramírez, B. (2022). Factores que limitan la adopción de Sistemas ERP en las PyMES mexicanas. *Revista de Ciencias Empresariales*, *10*(2), 55-70.

[31] Heizer, J., Render, B., & Munson, C. (2017). *Principles of Operations Management*. Pearson Education.

[32] IBM. (s.f.[a]). ¿Qué es el analytics de la cadena de suministro? https://www.ibm.com/mx-es/think/topics/supply-chain-analytics

[33] IBM. (s.f.[b]). ¿Qué es el deep learning?

[34] IBM. (s.f.[c]). ¿Qué es la gestión del inventario? https://www.ibm.com/mx-es/think/topics/inventory-management

[35] IBM. (s.f.[d]). ¿Qué es Random Forest?

[36] IBM. (s.f.[e]). ¿Qué son los modelos ARIMA? https://www.ibm.com/mx-es/think/topics/arima-model

[37] IBM. (s.f.[f]). Automatización de órdenes de compra. https://www.ibm.com/mx-es/think/topics/purchase-order-automation

[38] IBM. (s.f.[g]). Detalles estadísticos de previsión.

[39] Innowise. (s.f.). RPA en la cadena de suministro: Revolucionando la logística.

[40] Limitaciones del Modelo LSTM en la Predicción de Demanda Eléctrica con Datos Simulados de Bajo Volumen. (2025).

[41] Mag, I. M. (2025). Beneficios de la AI para empresas: aumenta la productividad.

[42] Martí Sanahuja, P. (2021). Métricas de evaluación de rendimiento para predicciones de series temporales.

[43] MasterBase®. (s.f.). Cómo la automatización de procesos revoluciona la gestión de inventarios.

[44] Mecalux. (2021, marzo). 5 problemas de logística más comunes que enfrentan las industrias.

[45] Mendoza-Delgado, M. A., Torres-Mayorga, A. F., & Alcaraz-Barriga, F. (2020). La transformación digital como factor de supervivencia en PyMEs en el contexto de la Industria 4.0. *Revista Global de Negocios*, *8*(1), 1-10.

[46] Monroy, F., & Mendoza, J. (2023). Factores del error humano en la toma de decisiones estratégicas en los niveles directivos de la Industria Siderúrgica Mexicana. *Vinculategica*, *3*.

[47] Montero, R., & García, I. (2008). Modelos de Gestión de Inventarios en Cadenas de Abastecimiento: Revisión de la Literatura. *Revista de Ingeniería*, (43), 101-110.

[48] MRPeasy. (2024). ¿Qué es el exceso de inventario y cómo evitarlo?

[49] n8n.io. (s.f.). n8n vs Zapier.

[50] Ortega, M., & Fernández, F. (2020). Optimización de la gestión de inventarios y procedimientos en el departamento de compras y almacenes: Un estudio de caso en EM. *Ciencia Latina Revista Científica Multidisciplinar*, *8*(1), 924-935.

[51] OTexts. (s.f.). 12.2 Modelo Prophet.

[52] Peña, B. E. (2011). Principales problemas de las PYMES por falta de información oportuna generada en sus sistemas contables. *Revista de Investigación Académica Sin Frontera*, (10), 1-12.

[53] Podadera Molero, A. (s.f.). *Modelización de Series Temporales modelos clásicos y SARIMA* [Trabajo de Fin de Máster en Estadística Aplicada]. Universidad de Granada.

[54] Poveda-Bautista, R., Sanchis, R., & Blasco-Peris, L. (2021). La transformación digital de las pymes: una revisión sistemática de la literatura y un modelo conceptual. *Revista Iberoamericana de Sistemas, Cibernética e Informática*, *18*(1), 21-42.

[55] PREDIK Data-Driven. (s.f.). ¿Cómo ayuda el análisis predictivo en las cadenas de suministro? https://predikdata.com/es/como-ayuda-el-analisis-predictivo-en-las-cadenas-de-suministro/

[56] Prism, S. B. (2024). Aproveche el ROI de su inversión en tecnología con la automatización.

[57] Ramírez, M. F., & Palacios, R. O. (2022). La barrera gerencial en la adopción del comercio electrónico en pymes mexicanas. *Revista Administración y Negocios*, *8*(1), 1-17.

[58] ResearchGate. (s.f.). Enhanching Prophet Time Series Forecasting on Sparse Data via Hyperparameter Optimizattion: A Case Study in Retail.

[59] Rojas, N., Orellana, N., & Orellana, J. (2019). Gestión de inventarios en pequeñas y medianas empresas: una revisión de literatura. *Revista de Investigación en Gestión de la Producción y Operaciones*, *1*(1), 12-25.

[60] Romero Agila, S. E., Sáenz Encalada, S. S., & Pacheco Molina, A. M. (2021). La Gestión de inventarios en las PYMES del sector de la construcción. *Pol. Con.*, *6*(9), 1495-1518.

[61] Ruiz Lanza, N. (2022). Fundamentos y variantes de los modelos ARIMA para el análisis de series temporales. Aplicación a la estadística universitaria.

[62] SAP. (2024). Automatización de procesos: la clave para la eficiencia.

[63] Schwaber, K., & Sutherland, J. (2020). The Scrum Guide: The Definitive Guide to Scrum: The Rules of the Game.

[64] SciELO México. (2020). Aplicación de algoritmos Random Forest y XGBoost en una base de solicitudes de tarjetas de crédito.

[65] SEIDOR. (2022). ¿Cuál es el precio de incorporar un ERP para una PYME?

[66] ServiceNow. (s.f.). ¿Qué es una integración de API?

[67] Services), A. (W. (s.f.). ¿Qué es el análisis predictivo? https://aws.amazon.com/es/what-is/predictive-analytics/

[68] Simchi-Levi, D., Kaminsky, P., & Simchi-Levi, E. (2008). *Designing and Managing the Supply Chain: Concepts, Strategies, and Case Studies*. McGraw-Hill/Irwin.

[69] Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, *72*(1), 37-45.

[70] Telefónica Tech. (2024). La IA Generativa en el ámbito de las series temporales.

[71] Transformación Tecnológica en el Modelo de Gestión de Inventarios en las Mipymes, Revisión Bibliográfica. (2024).

[72] Triangle. (2024). ¿Por qué las PyMES deben invertir en la nube?

[73] Universidad de Granada. (s.f.). Modelización de Series Temporales modelos clásicos y SARIMA.

[74] Universidad Nacional de Colombia (UNAL). (s.f.). Una comparación entre modelos estadísticos y de Machine Learning para la predicción de series de tiempo multivariadas.

[75] Unosquare. (2024). Digitalization, Digitization & Digital Transformation: What's the Difference?

[76] Wiese, W. (2019). De la automatización a los sistemas autónomos. *ABB Review*, (3).